

Fondamenti di Probabilità — Guida Esaustiva allo Studio

Corso: Fondamenti di Probabilità — Prof. Marco Lops *Università degli Studi di Napoli Federico II*

Indice

1	Spazi campionari ed eventi	3
1.1	Il concetto di esperimento casuale	3
1.2	Lo spazio campionario Ω	3
1.3	Gli eventi	3
1.4	Operazioni sugli eventi	3
1.5	Leggi di De Morgan	4
2	Analisi combinatoria	4
2.1	Perché serve il conteggio	4
2.2	Il principio moltiplicativo	4
2.3	Permutazioni	4
2.4	Disposizioni	4
2.5	Combinazioni	5
3	Misura di probabilità e assiomi	5
3.1	Che cos'è la probabilità	5
3.2	Gli assiomi di Kolmogorov	6
3.3	Conseguenze immediate degli assiomi	6
3.4	Probabilità uniforme su spazi finiti	7
4	Probabilità condizionata e indipendenza	7
4.1	La probabilità condizionata	7
4.2	La legge della probabilità totale	7
4.3	Il teorema di Bayes	8
4.4	Indipendenza tra eventi	8
5	Variabili aleatorie	8
5.1	Perché le variabili aleatorie	8
5.2	Variabili discrete e loro PMF	9
5.3	Variabili continue e loro PDF	9
5.4	La funzione di distribuzione cumulativa (CDF)	9
5.5	Valore atteso e varianza	10
6	Distribuzioni discrete notevoli	11
6.1	Distribuzione di Bernoulli	11
6.2	Distribuzione Binomiale	11
6.3	Distribuzione di Poisson	11
7	Distribuzioni continue notevoli	12
7.1	Distribuzione Uniforme	12
7.2	Distribuzione Normale (Gaussiana)	12
7.3	Distribuzione Esponenziale	13

8	Vettori aleatori, covarianza e correlazione	14
8.1	Distribuzioni congiunte	14
8.2	Indipendenza di variabili aleatorie	14
8.3	Covarianza	14
8.4	Matrice di covarianza	14
8.5	Coefficiente di correlazione	15
9	Legge dei grandi numeri e teorema centrale del limite	15
9.1	La legge debole dei grandi numeri	15
9.2	La disuguaglianza di Chebyshev	16
9.3	Il teorema centrale del limite	16
9.4	Convergenza in distribuzione	17
10	Esercizi risolti	17
10.1	Esercizio 1 — Analisi combinatoria e probabilità classica	17
10.2	Esercizio 2 — Teorema di Bayes	18
10.3	Esercizio 3 — Distribuzione binomiale e Poisson	18
10.4	Esercizio 4 — Distribuzione Normale e TCL	19
10.5	Esercizio 5 — Disuguaglianza di Chebyshev vs Normale	19
11	Tavola riassuntiva delle distribuzioni	21

1 Spazi campionari ed eventi

1.1 Il concetto di esperimento casuale

Il punto di partenza di tutta la teoria della probabilità è l'**esperimento casuale**: un'operazione il cui esito dipende dal caso e non è prevedibile con certezza, nemmeno se si conoscono tutte le condizioni iniziali.

Esempio intuitivo: lanciare una moneta, estrarre una carta da un mazzo, misurare il tempo di attesa a uno sportello, osservare quanti pacchetti arrivano in un secondo su una rete. In tutti questi casi sappiamo *cosa potrebbe accadere*, ma non *cosa accadrà*.

Questa incertezza è la materia prima della probabilità. Il nostro obiettivo è modellarla con rigore matematico.

1.2 Lo spazio campionario Ω

Definizione. Lo **spazio campionario** Ω è l'insieme di tutti i possibili esiti di un esperimento casuale. Ogni elemento $\omega \in \Omega$ è detto **esito elementare**.

Lo spazio campionario è il “mondo possibile” dell'esperimento: prima di osservare il risultato, tutto ciò che può avvenire è contenuto in Ω . La sua struttura dipende dall'esperimento:

- **Finito:** numero limitato di esiti. *Esempio:* lancio di un dado, $\Omega = \{1, 2, 3, 4, 5, 6\}$.
- **Numerabile:** infiniti esiti, ma elencabili. *Esempio:* numero di clienti in coda, $\Omega = \{0, 1, 2, 3, \dots\}$.
- **Continuo (non numerabile):** *Esempio:* tempo di attesa, $\Omega = [0, +\infty)$; temperatura, $\Omega = \mathbb{R}$.

1.3 Gli eventi

Definizione. Un **evento** A è un qualunque sottoinsieme di Ω . Diciamo che A si **verifica** se l'esito osservato ω appartiene ad A .

La distinzione tra esito elementare ed evento è sottile ma importante. Un esito è un singolo risultato; un evento è una *collezione* di risultati che ci interessa raggruppare. Nel lancio di un dado:

- “ottenere 4” è un evento elementare: $\{4\}$;
- “ottenere un numero pari” è l'evento $\{2, 4, 6\}$;
- “ottenere almeno 3” è l'evento $\{3, 4, 5, 6\}$.

Due eventi speciali hanno un nome:

- Ω è l'**evento certo**: si verifica qualunque cosa accada.
- $\emptyset$ è l'**evento impossibile**: non si verifica mai.

1.4 Operazioni sugli eventi

Gli eventi si combinano con le stesse operazioni insiemistiche. Il significato probabilistico è intuitivo:

Operazione	Notazione	Si verifica quando...
Unione	$A \cup B$	si verifica <i>A</i> oppure <i>B</i> (o entrambi)
Intersezione	$A \cap B$	si verificano sia <i>A</i> che <i>B</i>
Complementare	$\bar{A} = \Omega \setminus A$	<i>A</i> non si verifica
Differenza	$A \setminus B = A \cap \bar{B}$	si verifica <i>A</i> ma non <i>B</i>

Due eventi A e B si dicono **incompatibili** (o mutuamente esclusivi) se $A \cap B = \emptyset$: non possono verificarsi contemporaneamente. L'incompatibilità è molto diversa dall'indipendenza — torneremo su questo punto nella Sezione 3.

1.5 Leggi di De Morgan

Le leggi di De Morgan traducono il complementare di un'unione (o intersezione) in termini più semplici:

$$\overline{A \cup B} = \bar{A} \cap \bar{B}, \quad \overline{A \cap B} = \bar{A} \cup \bar{B}.$$

Perché sono utili? Spesso è più facile calcolare $P(\bar{A} \cap \bar{B})$ che $P(\overline{A \cup B})$; le leggi di De Morgan garantiscono che siano la stessa cosa.

Lettura intuitiva della prima: “non (A oppure B)” equivale a “né A né B”. Se non piove e non grandina, allora certamente non accade né pioggia né grandine.

2 Analisi combinatoria

2.1 Perché serve il conteggio

Quando tutti gli esiti elementari sono equiprobabili, la probabilità di un evento è semplicemente il rapporto tra il numero di esiti favorevoli e il numero totale di esiti. Il problema si riduce a *contare* correttamente. L'analisi combinatoria fornisce gli strumenti per farlo senza dover elencare tutti i casi uno per uno.

2.2 Il principio moltiplicativo

Principio moltiplicativo. Se un esperimento si compone di k fasi indipendenti, con n_1 possibili esiti alla prima fase, n_2 alla seconda, $\dots$, n_k all'ultima, allora il numero totale di possibili sequenze di esiti è:

$$N = n_1 \times n_2 \times \dots \times n_k.$$

Esempio intuitivo: un menù offre 4 primi, 5 secondi e 3 dolci. Il numero di pasti completi che si possono ordinare è $4 \times 5 \times 3 = 60$. Per ogni scelta di primo restano 5 opzioni di secondo — il principio moltiplicativo cattura esattamente questa struttura “a ramificazioni”.

2.3 Permutazioni

Definizione. Una **permutazione** di n elementi distinti è un ordinamento di tutti gli n elementi. Il numero di permutazioni è:

$$P_n = n! = n \cdot (n-1) \cdot (n-2) \dots 2 \cdot 1.$$

Il ragionamento è semplice: per la prima posizione abbiamo n scelte, per la seconda $n-1$ (un elemento è già stato collocato), per la terza $n-2$, e così via. Per il principio moltiplicativo: $n \cdot (n-1) \dots 1 = n!$.

Esempio: quanti anagrammi (non necessariamente di senso compiuto) si possono formare con le lettere di “ROMA”? Sono $4! = 24$.

Nota: per convenzione $0! = 1$.

2.4 Disposizioni

Le disposizioni generalizzano le permutazioni al caso in cui non si dispongono tutti gli n elementi, ma solo k di essi (con l'ordine che conta).

Definizione. Il numero di **disposizioni** di n elementi in k posti (senza ripetizione, $k \leq n$) è:

$$D_{n,k} = \frac{n!}{(n-k)!} = n(n-1) \cdots (n-k+1).$$

Esempio intuitivo: in una gara con 10 atleti, quanti possibili podi (oro, argento, bronzo) esistono? Primo posto: 10 scelte; secondo: 9; terzo: 8. Totale: $10 \times 9 \times 8 = 720 = D_{10,3}$.

2.5 Combinazioni

Nelle disposizioni l'ordine conta: (oro=Mario, argento=Luigi) è diverso da (oro=Luigi, argento=Mario). Le **combinazioni** si usano invece quando vogliamo scegliere un sottoinsieme e l'ordine *non* conta.

Definizione. Il numero di **combinazioni** di n elementi scelti k alla volta (senza ripetizione) è:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

Come ci arriviamo. Le disposizioni $D_{n,k}$ contano le sequenze ordinate di k elementi. Ogni sottoinsieme di k elementi viene contato esattamente $k!$ volte (tante quante sono le sue permutazioni). Quindi:

$$\binom{n}{k} = \frac{D_{n,k}}{k!} = \frac{n!}{k!(n-k)!}.$$

Esempio: una commissione di 3 persone va scelta tra 10 candidati. Quante commissioni sono possibili? $\binom{10}{3} = \frac{10 \cdot 9 \cdot 8}{3!} = 120$.

Proprietà fondamentali:

- $\binom{n}{0} = \binom{n}{n} = 1$
- *Simmetria:* $\binom{n}{k} = \binom{n}{n-k}$ (scegliere chi include o chi esclude)
- *Identità di Pascal:* $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$

3 Misura di probabilità e assiomi

3.1 Che cos'è la probabilità

La probabilità nasce dall'esigenza di quantificare l'incertezza. Storicamente esistono tre interpretazioni principali:

- **Frequentista:** $P(A)$ è il limite della frequenza relativa di A in infinite ripetizioni dell'esperimento. Intuitiva per fenomeni ripetibili (monete, dadi), ma inapplicabile a eventi unici ("probabilità che piova domani").
- **Classica (Laplace):** se tutti gli esiti sono equiprobabili, $P(A) = |A|/|\Omega|$. Semplice, ma limitata agli spazi finiti uniformi.
- **Soggettiva (Bayesiana):** $P(A)$ misura il grado di credenza personale nel verificarsi di A , aggiornabile con l'evidenza tramite il teorema di Bayes.

Qualunque interpretazione si adotti, la struttura matematica è la stessa: quella degli assiomi di Kolmogorov.

Definizione (σ -algebra). Una σ -algebra $\mathcal{F}$ su Ω è una famiglia di sottoinsiemi di Ω che soddisfa:

1. $\Omega \in \mathcal{F}$
2. Se $A \in \mathcal{F}$, allora $\bar{A} \in \mathcal{F}$ (chiusura per il complemento)
3. Se $A_1, A_2, \dots \in \mathcal{F}$, allora $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$ (chiusura per unioni numerabili)

Gli elementi di $\mathcal{F}$ sono gli **eventi**, cioè i sottoinsiemi di Ω ai quali è lecito assegnare una probabilità.

La σ -algebra nasce da un'esigenza tecnica: in spazi continui non è possibile assegnare una probabilità coerente a *tutti* i sottoinsiemi di Ω (esistono insiemi patologici, detti non misurabili, per i quali qualsiasi tentativo porta a contraddizioni). La σ -algebra delimita la famiglia degli insiemi “ben comportati” su cui la probabilità è definita. In pratica, per tutti gli spazi campionari che incontriamo in questo corso, $\mathcal{F}$ contiene tutti i sottoinsiemi che ci interessano e non occorre preoccuparsene esplicitamente.

3.2 Gli assiomi di Kolmogorov

Definizione. Una **misura di probabilità** è una funzione $P : \mathcal{F} \rightarrow [0, 1]$ (dove $\mathcal{F}$ è una famiglia di sottoinsiemi di Ω , detta σ -algebra) che soddisfa:

1. **Non negatività:** $P(A) \geq 0$ per ogni $A \in \mathcal{F}$.
2. **Normalizzazione:** $P(\Omega) = 1$.
3. **Additività σ :** se $A_1, A_2, \dots$ sono a due a due incompatibili ($A_i \cap A_j = \emptyset$ per $i \neq j$), allora

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Questi tre assiomi sono la base di tutta la teoria. Da essi, con sola logica insiemistica, si ricavano tutte le proprietà operative della probabilità.

3.3 Conseguenze immediate degli assiomi

Probabilità dell'evento impossibile. Poiché Ω e $\emptyset$ sono incompatibili e $\Omega \cup \emptyset = \Omega$:

$$P(\Omega) = P(\Omega) + P(\emptyset) \implies P(\emptyset) = 0.$$

Regola del complementare. Poiché A e $\bar{A}$ sono incompatibili e $A \cup \bar{A} = \Omega$:

$$P(A) + P(\bar{A}) = 1 \implies \boxed{P(\bar{A}) = 1 - P(A)}.$$

Questa è una delle formule più usate in pratica: spesso è più facile calcolare la probabilità del complementare.

Monotonia. Se $A \subseteq B$, allora $P(A) \leq P(B)$. Intuitivo: un evento più “grande” (che contiene più esiti) ha probabilità maggiore o uguale.

Regola dell'unione. Per due eventi qualsiasi (anche non incompatibili):

$$\boxed{P(A \cup B) = P(A) + P(B) - P(A \cap B)}.$$

Si sottrae $P(A \cap B)$ perché gli esiti in $A \cap B$ sono stati contati due volte — una per A e una per B .

3.4 Probabilità uniforme su spazi finiti

Quando $\Omega = \{\omega_1, \dots, \omega_N\}$ è finito e tutti gli esiti sono equiprobabili, dalla normalizzazione segue $P(\{\omega_i\}) = 1/N$ per ogni i . Allora:

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{numero di esiti favorevoli}}{\text{numero totale di esiti}}.$$

Questa è la **definizione classica di Laplace**. È esatta quando lo spazio è finito e la simmetria giustifica l'equiprobabilità (dado non truccato, mazzo mescolato correttamente, ecc.).

Esempio intuitivo: in un mazzo standard di 52 carte, qual è la probabilità di estrarne un asso? Ci sono 4 assi e 52 carte totali, quindi $P(\text{asso}) = 4/52 = 1/13 \approx 7.7\%$.

4 Probabilità condizionata e indipendenza

4.1 La probabilità condizionata

Nella pratica, raramente ragioniamo nel vuoto: spesso abbiamo *informazioni parziali* che cambiano le nostre stime. La probabilità condizionata formalizza questo aggiornamento.

Esempio intuitivo: si lancia un dado. Senza informazioni aggiuntive, la probabilità di ottenere 6 è $1/6$. Se però qualcuno ci dice “il risultato è pari”, la nostra stima cambia: tra i risultati pari $\{2, 4, 6\}$ uno solo è 6, quindi la probabilità diventa $1/3$.

Definizione. La **probabilità di A condizionata a B** è definita, per $P(B) > 0$, come:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Interpretazione geometrica. Sapere che B si è verificato equivale a “restringere” lo spazio campionario a B . All'interno di B , la porzione favorevole ad A è $A \cap B$. La probabilità condizionata ridimensiona questa porzione in modo che $P(B | B) = 1$.

Dalla definizione si ricava immediatamente la **regola del prodotto**:

$$P(A \cap B) = P(A | B) P(B) = P(B | A) P(A).$$

Questa formula si generalizza a più eventi (regola della catena):

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \dots$$

4.2 La legge della probabilità totale

Immaginiamo di dover calcolare $P(A)$, ma che sia conveniente “condizionare” rispetto a uno scenario intermedio. Se $B_1, B_2, \dots, B_n$ formano una **partizione** di Ω (cioè sono incompatibili e la loro unione è Ω), allora ogni esito di A deve passare da uno e uno solo dei B_i :

Legge della probabilità totale.

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i).$$

Esempio intuitivo: un'azienda ha tre turni di lavoro (mattina, pomeriggio, notte) che coprono il 100% delle ore. La probabilità che un pezzo difettoso venga prodotto dipende dal turno. La probabilità totale di difetto è la media pesata dei tassi di difetto per turno, con peso pari alla quota di produzione di ogni turno.

4.3 Il teorema di Bayes

Il teorema di Bayes risponde a una domanda cruciale: abbiamo osservato A ; qual è la probabilità che provenga dallo scenario B_i ?

Teorema di Bayes. Nelle stesse ipotesi della legge della probabilità totale:

$$P(B_i | A) = \frac{P(A | B_i) P(B_i)}{\sum_{j=1}^n P(A | B_j) P(B_j)}.$$

La formula combina:

- $P(B_i)$: **probabilità a priori** dello scenario B_i (prima di osservare A);
- $P(A | B_i)$: **verosimiglianza** di osservare A dato B_i ;
- $P(B_i | A)$: **probabilità a posteriori** di B_i dopo aver osservato A .

Il teorema di Bayes è il fondamento della statistica Bayesiana: formalizza come l'osservazione dei dati aggiorna le nostre credenze sulle ipotesi.

4.4 Indipendenza tra eventi

Definizione. Due eventi A e B sono **indipendenti** se:

$$P(A \cap B) = P(A) P(B).$$

Equivalentemente (per $P(B) > 0$): $P(A | B) = P(A)$, cioè conoscere B non modifica la probabilità di A .

Attenzione: indipendenza e incompatibilità sono concetti *opposti*, non equivalenti. Se A e B sono incompatibili e hanno probabilità positiva, non possono essere indipendenti: sapere che B è avvenuto rende A *impossibile*, quindi la conoscenza di B modifica eccome la probabilità di A .

Esempio intuitivo: il risultato del primo lancio di una moneta è indipendente dal secondo. Il colore di un pelo estratto da un cane non è indipendente dalla razza del cane.

Per n eventi $A_1, \dots, A_n$, l'indipendenza *reciproca* (o congiunta) richiede che per ogni sottoinsieme di indici $I \subseteq \{1, \dots, n\}$:

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i).$$

Non basta l'indipendenza a coppie!

5 Variabili aleatorie

5.1 Perché le variabili aleatorie

Lavorare direttamente con gli esiti $\omega \in \Omega$ è spesso scomodo. Preferibilmente vogliamo associare a ogni esito un *numero*: il punteggio di un dado, il numero di guasti, la temperatura misurata. Le variabili aleatorie svolgono esattamente questo ruolo.

Definizione. Una **variabile aleatoria** (v.a.) X è una funzione

$$X : \Omega \rightarrow \mathbb{R}$$

che associa a ogni esito ω un valore numerico $X(\omega)$.

Esempio intuitivo: nel lancio di due dadi, $\omega = (3, 5)$ è un esito. La variabile $X(\omega) = 3 + 5 = 8$ rappresenta la somma. La variabile $Y(\omega) = \max(3, 5) = 5$ rappresenta il massimo. Stesso esperimento, variabili diverse.

5.2 Variabili discrete e loro PMF

Definizione. Una v.a. X è **discreta** se assume un insieme finito o numerabile di valori $\{x_1, x_2, \dots\}$.

La **funzione di massa di probabilità** (PMF) è:

$$p_X(x) = P(X = x), \quad x \in \mathbb{R}.$$

La PMF soddisfa $p_X(x) \geq 0$ e $\sum_x p_X(x) = 1$. Essa descrive completamente la distribuzione di X : se conosciamo p_X , possiamo calcolare la probabilità di qualsiasi evento legato a X .

La PMF non è una misura di probabilità perchè è definita su valori della variabile aleatoria e non sugli eventi della σ -algebra

Esempio: X = numero uscito dal lancio di un dado equo. Allora $p_X(k) = 1/6$ per $k \in \{1, \dots, 6\}$ e zero altrove.

5.3 Variabili continue e loro PDF

Definizione. Una v.a. X è **continua** se esiste una funzione $f_X(x) \geq 0$ — detta **densità di probabilità** (PDF) — tale che:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1.$$

A differenza del caso discreto, per una v.a. continua $P(X = x) = 0$ per ogni singolo valore x : ha senso parlare di probabilità solo su intervalli. La densità $f_X(x)$ non è una probabilità: può essere maggiore di 1; è la probabilità *per unità di x* .

5.4 La funzione di distribuzione cumulativa (CDF)

Unifica il trattamento di variabili discrete e continue.

Definizione. La **CDF** di una v.a. X è:

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Proprietà della CDF:

1. *Non decrescente:* se $x_1 < x_2$ allora $F_X(x_1) \leq F_X(x_2)$.
2. *Limiti:* $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. *Continua da destra:* $\lim_{y \downarrow x} F_X(y) = F_X(x)$.

Nel caso continuo si ha $f_X(x) = F'_X(x)$ quasi ovunque, cioè la **PMF** è la derivata della **CDF**.
Nota. La CDF non è una probabilità, bensì una funzione che associa a ogni valore x la probabilità dell'evento $\{X \leq x\}$. Ogni valore della CDF è quindi una probabilità compresa tra 0 e 1.

Dimostrazione delle proprietà della CDF:

Proprietà 1 (non decrescenza). Siano $x_1 < x_2$. Allora $\{X \leq x_1\} \subseteq \{X \leq x_2\}$, quindi per monotonia della probabilità:

$$F_X(x_1) = P(X \leq x_1) \leq P(X \leq x_2) = F_X(x_2). \quad \square$$

Proprietà 2 (limiti). Per il limite inferiore, si consideri la successione di eventi $A_n = \{X \leq -n\}$, decrescente verso $\emptyset$:

$$A_1 \supseteq A_2 \supseteq \cdots, \quad \bigcap_{n=1}^{\infty} A_n = \emptyset.$$

Per la continuità della probabilità rispetto a successioni decrescenti:

$$\lim_{n \rightarrow \infty} F_X(-n) = P\left(\bigcap_{n=1}^{\infty} A_n\right) = P(\emptyset) = 0.$$

Analogamente, sia $B_n = \{X \leq n\}$, crescente verso Ω :

$$\lim_{n \rightarrow \infty} F_X(n) = P\left(\bigcup_{n=1}^{\infty} B_n\right) = P(\Omega) = 1. \quad \square$$

Proprietà 3 (continuità da destra). Fissato x , si consideri la successione $y_n = x + 1/n \downarrow x$. Gli eventi $C_n = \{X \leq x + 1/n\}$ sono decrescenti e la loro intersezione è:

$$\bigcap_{n=1}^{\infty} C_n = \{X \leq x\}.$$

Quindi, di nuovo per continuità della probabilità:

$$\lim_{n \rightarrow \infty} F_X(x + \frac{1}{n}) = P\left(\bigcap_{n=1}^{\infty} C_n\right) = P(X \leq x) = F_X(x). \quad \square$$

Osservazione. La CDF è continua da destra ma non necessariamente da sinistra: nei punti di discontinuità (che per v.a. discrete coincidono con i valori di massa positiva) si ha $F_X(x) - \lim_{y \uparrow x} F_X(y) = P(X = x) > 0$.

5.5 Valore atteso e varianza**Definizione di Media (valore atteso).**

$$\mathbb{E}[X] = \begin{cases} \sum x p_X(x) & \text{caso discreto} \\ \int_{-\infty}^{+\infty} x f_X(x) dx & \text{caso continuo} \end{cases}$$

Il valore atteso è il “baricentro” della distribuzione: il valore medio che ci si aspetta nel lungo periodo con molte ripetizioni dell’esperimento. È una media pesata di tutti i valori possibili, con peso pari alla loro probabilità.

Definizione (varianza).

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

La **deviazione standard** è $\sigma_X = \sqrt{\text{Var}(X)}$.

La varianza misura quanto i valori di X si disperdono attorno alla media. Una varianza piccola significa che X è quasi sempre vicino a $\mathbb{E}[X]$; una varianza grande indica alta dispersione.

Proprietà fondamentali:

- *Linearità del valore atteso:* $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$.
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$ (traslare non cambia la dispersione; scalare la moltiplica).
- Se X e Y sono indipendenti: $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.
- Se X e Y sono indipendenti: $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

6 Distribuzioni discrete notevoli

6.1 Distribuzione di Bernoulli

Distribuzione di Bernoulli: $X \sim \text{Ber}(p)$. Modella un esperimento con soli due esiti: successo ($X = 1$, probabilità p) e fallimento ($X = 0$, probabilità $1 - p$).

PMF: $p_X(1) = p$, $p_X(0) = 1 - p$.

Media e varianza: $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1 - p)$.

Esempio: lancio di una moneta con probabilità di testa p . Anche la risposta corretta/sbagliata a una domanda a scelta multipla, o il funzionamento/guasto di un componente.

La varianza è massima per $p = 1/2$ (massima incertezza) e vale zero per $p \in \{0, 1\}$ (nessuna incertezza).

6.2 Distribuzione Binomiale

Distribuzione Binomiale: $X \sim B(n, p)$. X conta il numero di successi in n prove di Bernoulli indipendenti, ciascuna con probabilità di successo p .

PMF: $p_X(k) = \binom{n}{k} p^k (1 - p)^{n-k}$, per $k = 0, 1, \dots, n$.

Media e varianza: $\mathbb{E}[X] = np$, $\text{Var}(X) = np(1 - p)$.

Come leggere la PMF. Per ottenere esattamente k successi: scelgo quali k prove sono successi in $\binom{n}{k}$ modi; la probabilità di ciascuna di queste configurazioni è $p^k(1 - p)^{n-k}$.

Esempio intuitivo: uno studente risponde a caso a 10 domande vero/falso. Il numero di risposte corrette è $X \sim B(10, 0.5)$. In media si aspetta $10 \times 0.5 = 5$ risposte corrette.

6.3 Distribuzione di Poisson

Distribuzione di Poisson: $X \sim \text{Pois}(\lambda)$. Modella il numero di eventi rari che accadono indipendentemente in un intervallo fisso, con tasso medio λ .

PMF: $p_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}$, per $k = 0, 1, 2, \dots$

Media e varianza: $\mathbb{E}[X] = \lambda$, $\text{Var}(X) = \lambda$.

Una caratteristica unica della Poisson: **media e varianza coincidono**. Questo rende facile identificare questa distribuzione in pratica: se la varianza campionaria è molto diversa dalla media, la Poisson non è adeguata.

Legame con la Binomiale. Se n è grande e p è piccolo, ma $\lambda = np$ rimane costante, allora $B(n, p) \approx \text{Pois}(\lambda)$. Regola pratica: usare l'approssimazione Poisson per $n \geq 20$ e $p \leq 0.05$.

Esempio intuitivo: il numero di errori tipografici per pagina in un libro, il numero di telefonate in arrivo in un call center in un minuto, il numero di fotoni che colpiscono un sensore in un microsecondo.

7 Distribuzioni continue notevoli

7.1 Distribuzione Uniforme

Distribuzione Uniforme: $X \sim U(a, b)$. Tutti i valori nell'intervallo $[a, b]$ sono equiprobabili.

PDF: $f_X(x) = \frac{1}{b-a}$ per $a \leq x \leq b$, zero altrove.

CDF: $F_X(x) = \frac{x-a}{b-a}$ per $a \leq x \leq b$.

Media e varianza: $\mathbb{E}[X] = \frac{a+b}{2}$, $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Esempio intuitivo: un bus arriva ogni 20 minuti. Se si arriva alla fermata in un istante casuale, il tempo di attesa è $U(0, 20)$. In media si aspetta 10 minuti.

7.2 Distribuzione Normale (Gaussiana)

La distribuzione più importante della statistica. Emerge naturalmente come distribuzione limite di somme di variabili aleatorie (Teorema Centrale del Limite).

Distribuzione Normale: $X \sim \mathcal{N}(\mu, \sigma^2)$.

PDF: $f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$, per $x \in \mathbb{R}$.

Media e varianza: $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$.

La curva è a forma di “campana”, simmetrica attorno a μ . Il parametro σ controlla la larghezza: σ grande $\rightarrow$ curva larga e bassa; σ piccolo $\rightarrow$ curva stretta e alta.

Normalizzazione (standardizzazione). Per qualsiasi $X \sim \mathcal{N}(\mu, \sigma^2)$:

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1).$$

La **normale standard** $Z \sim \mathcal{N}(0, 1)$ ha CDF denotata $\Phi(z)$, tabellata o disponibile in qualsiasi software. La probabilità di qualsiasi evento gaussiano si calcola tramite questa tabella.

Regola 68-95-99.7:

- $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 68.27\%$
- $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 95.45\%$
- $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 99.73\%$

Proprietà della distribuzione normale:

- **Stabilità per trasformazioni lineari.** Se $X \sim \mathcal{N}(\mu, \sigma^2)$ e $Y = aX + b$ con $a \neq 0$, allora:

$$Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

La famiglia gaussiana è chiusa rispetto alle trasformazioni lineari: una combinazione lineare di una gaussiana è ancora gaussiana.

- **Somma di gaussiane indipendenti.** Se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$ e $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$ sono indipendenti, allora:

$$X + Y \sim \mathcal{N}(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2).$$

Più in generale, se $X_1, \dots, X_n$ sono i.i.d. con legge $\mathcal{N}(\mu, \sigma^2)$:

$$\sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2), \quad \bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Questa proprietà è esatta (non approssimata come nel TCL) e spiega perché la media campionaria di dati gaussiani è esattamente gaussiana per qualsiasi n .

- **Scorrelazione implica indipendenza.** Se (X, Y) sono congiuntamente gaussiani e $\text{Cov}(X, Y) = 0$, allora X e Y sono indipendenti. Questa proprietà è esclusiva del caso gaussiano: in generale, scorrelazione non implica indipendenza.
- **Distribuzione chi-quadrato.** Se $Z_1, \dots, Z_k$ sono i.i.d. $\mathcal{N}(0, 1)$, allora la somma dei quadrati segue una distribuzione **chi-quadrato** con k gradi di libertà:

$$\sum_{i=1}^k Z_i^2 \sim \chi^2(k), \quad \mathbb{E}[\chi^2(k)] = k, \quad \text{Var}(\chi^2(k)) = 2k.$$

Questa distribuzione emerge naturalmente nella stima della varianza campionaria e nei test di adattamento.

- **Gaussiana multivariata.** Il vettore aleatorio $\mathbf{X} = (X_1, \dots, X_n)^T$ è **gaussiano multivariato** $\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$ se la sua PDF è:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right).$$

La distribuzione è completamente specificata da media μ e matrice di covarianza Σ . L'argomento dell'esponente $(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)$ è detto **distanza di Mahalanobis** al quadrato e generalizza il termine $(x - \mu)^2 / \sigma^2$ del caso scalare.

Perché la normale è ovunque? Altezze, errori di misura, punteggi di test, fluttuazioni finanziarie: molti fenomeni reali sono somme di tanti contributi indipendenti e piccoli. Il TCL (Sezione 9) garantisce che tali somme siano approssimativamente normali.

7.3 Distribuzione Esponenziale

Distribuzione Esponenziale: $X \sim \text{Exp}(\lambda)$. Modella il tempo tra eventi successivi in un processo di Poisson.

PDF: $f_X(x) = \lambda e^{-\lambda x}$, per $x \geq 0$.

CDF: $F_X(x) = 1 - e^{-\lambda x}$, per $x \geq 0$.

Media e varianza: $\mathbb{E}[X] = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$.

Proprietà di assenza di memoria. Per $s, t \geq 0$:

$$P(X > s + t \mid X > s) = P(X > t).$$

Interpretazione: se un componente elettronico ha vita esponenziale ed è già sopravvissuto s ore, la probabilità di sopravvivere altre t ore è la stessa di un componente nuovo. Non invecchia. Questo rende l'esponenziale un modello idealizzato: nella realtà i componenti invecchiano (Weibull è più realistico), ma l'esponenziale è matematicamente trattabile.

8 Vettori aleatori, covarianza e correlazione

8.1 Distribuzioni congiunte

Spesso si osservano più variabili aleatorie insieme: altezza e peso di una persona, tensione e corrente in un circuito, temperatura e umidità.

Definizione. La **distribuzione congiunta** di (X, Y) è descritta dalla PMF congiunta $p_{X,Y}(x, y) = P(X = x, Y = y)$ (caso discreto) o dalla PDF congiunta $f_{X,Y}(x, y)$ tale che $P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy$ (caso continuo).

Distribuzioni marginali. Si ottengono “integrando via” l’altra variabile:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx.$$

8.2 Indipendenza di variabili aleatorie

Definizione. X e Y sono **indipendenti** se la distribuzione congiunta fattorizza nel prodotto delle marginali:

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y) \quad \text{per tutti } x, y.$$

Intuitivamente: conoscere il valore di X non fornisce alcuna informazione sul valore di Y .

8.3 Covarianza

Covarianza:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

La covarianza misura se X e Y tendono a spostarsi nella stessa direzione ($\text{Cov} > 0$), in direzioni opposte ($\text{Cov} < 0$) o in modo non correlato ($\text{Cov} = 0$).

Proprietà notevoli:

- $\text{Cov}(X, X) = \text{Var}(X)$.
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$.
- Se X, Y indipendenti $\Rightarrow \text{Cov}(X, Y) = 0$. Il contrario **non** vale in generale.

8.4 Matrice di covarianza

La covarianza scalare descrive la relazione tra due sole variabili. Quando si lavora con un vettore aleatorio $\mathbf{X} = (X_1, \dots, X_n)^T$, la covarianza tra ogni coppia di componenti si raccoglie in un’unica struttura matriciale. Questo è il punto di collegamento naturale tra probabilità e algebra lineare, ed è indispensabile in tutti i contesti multivariati: statistica, machine learning, elaborazione dei segnali.

Definizione. La **matrice di covarianza** di $\mathbf{X} = (X_1, \dots, X_n)^T$ con media $\mu = \mathbb{E}[\mathbf{X}]$ è:

$$\Sigma = \text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T] \in \mathbb{R}^{n \times n},$$

con elemento (i, j) :

$$\Sigma_{ij} = \text{Cov}(X_i, X_j) = \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)].$$

Come si legge. Σ contiene tutta l'informazione del secondo ordine sul vettore $\mathbf{X}$:

- La **diagonale** $\Sigma_{ii} = \text{Var}(X_i)$ raccoglie le varianze delle singole componenti.
- Gli **elementi fuori diagonale** Σ_{ij} (con $i \neq j$) misurano la covarianza tra X_i e X_j .

Esempio intuitivo: si misurano altezza e peso di una persona. Il vettore $\mathbf{X} = (\text{altezza}, \text{peso})^T$ ha una matrice di covarianza 2×2 :

$$\Sigma = \begin{pmatrix} \text{Var}(\text{altezza}) & \text{Cov}(\text{altezza}, \text{peso}) \\ \text{Cov}(\text{peso}, \text{altezza}) & \text{Var}(\text{peso}) \end{pmatrix}.$$

Poiché le due quantità sono positivamente correlate, ci si aspetta $\Sigma_{12} > 0$.

Proprietà fondamentali:

- **Simmetria:** $\Sigma = \Sigma^T$, poiché $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$.
- **Semidefinita positiva:** per ogni vettore deterministico $\mathbf{a} \in \mathbb{R}^n$:

$$\mathbf{a}^T \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^T \mathbf{X}) \geq 0.$$

Se le componenti non sono combinazioni lineari l'una dell'altra, Σ è definita positiva e quindi invertibile.

- **Formula compatta:** $\Sigma = \mathbb{E}[\mathbf{X}\mathbf{X}^T] - \mu\mu^T$, analoga alla formula scalare $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

Trasformazioni lineari. Se $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ con $\mathbf{A}$ matrice e $\mathbf{b}$ vettore deterministici:

$$\text{Cov}(\mathbf{Y}) = \mathbf{A} \Sigma \mathbf{A}^T.$$

Questa formula generalizza $\text{Var}(aX+b) = a^2\text{Var}(X)$ ed è alla base di PCA, filtro di Kalman e stimatore LMMSE.

Caso di componenti indipendenti. Se $X_1, \dots, X_n$ sono indipendenti, Σ è diagonale:

$$\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_n^2).$$

Attenzione: il viceversa non vale in generale. Matrice diagonale implica solo *scorrelazione*, non indipendenza. Fa eccezione il caso Gaussiano multivariato, dove le due nozioni coincidono.

8.5 Coefficiente di correlazione

Il difetto della covarianza è che dipende dalle unità di misura: raddoppiare l'unità di misura di X raddoppia $\text{Cov}(X, Y)$, rendendo difficile confrontare coppie diverse. Si normalizza dividendo per le deviazioni standard:

Coefficiente di correlazione di Pearson:

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1].$$

$|\rho| = 1$ indica una relazione lineare perfetta; $\rho = 0$ indica assenza di correlazione *lineare* (non necessariamente indipendenza!).

9 Legge dei grandi numeri e teorema centrale del limite

9.1 La legge debole dei grandi numeri

Legge Debole dei Grandi Numeri (LDGN). Siano $X_1, X_2, \dots$ v.a. i.i.d. con media μ e varianza $\sigma^2 < \infty$. Sia $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Allora per ogni $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) = 0.$$

In parole: al crescere della dimensione campionaria, la media campionaria $\bar{X}_n$ converge in probabilità alla vera media μ . Più dati raccogliamo, più siamo certi di essere vicini al valore vero.

Dimostrazione rapida (disuguaglianza di Chebyshev). Si calcola $\mathbb{E}[\bar{X}_n] = \mu$ e $\text{Var}(\bar{X}_n) = \sigma^2/n$. Applicando Chebyshev:

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0. \quad \square$$

Rilevanza pratica. La LDGN giustifica l'intero edificio della statistica descrittiva: usare la media campionaria per stimare la media della popolazione è corretto, e l'errore diventa arbitrariamente piccolo con abbastanza dati.

9.2 La disuguaglianza di Chebyshev

Merita una sezione propria perché è uno strumento universale: vale per *qualsiasi* distribuzione con varianza finita.

Disuguaglianza di Chebyshev. Per ogni v.a. X con $\mathbb{E}[X] = \mu$ e $\text{Var}(X) = \sigma^2$, e per ogni $\varepsilon > 0$:

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

Il risultato è spesso conservativo (il vero valore può essere molto più piccolo del limite), ma ha il pregio di non richiedere alcuna assunzione sulla forma della distribuzione.

Esempio: un processo produce viti di lunghezza media 50 mm e deviazione standard 2 mm. Senza sapere la distribuzione, possiamo dire: $P(|X - 50| \geq 6) \leq 4/36 \approx 11.1\%$.

Dimostrazione. Sia $A = \{|X - \mu| \geq \varepsilon\}$. Allora:

$$\sigma^2 = \mathbb{E}[(X - \mu)^2] \geq \mathbb{E}[(X - \mu)^2 \cdot \mathbf{1}_A] \geq \varepsilon^2 P(A),$$

da cui $P(A) \leq \sigma^2/\varepsilon^2$. $\square$

9.3 Il teorema centrale del limite

Il teorema centrale del limite (TCL) è uno dei risultati più potenti e sorprendenti della teoria della probabilità.

Teorema Centrale del Limite. Siano $X_1, X_2, \dots$ v.a. i.i.d. con media μ e varianza $\sigma^2 < \infty$. Sia:

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}}.$$

Allora:

$$Z_n \xrightarrow{d} \mathcal{N}(0, 1), \quad \text{cioè} \quad \lim_{n \rightarrow \infty} P(Z_n \leq z) = \Phi(z) \quad \text{per ogni } z.$$

Cosa significa. Qualunque sia la distribuzione originale di X_i — uniforme, Poisson, esponenziale, qualsiasi altra — la media campionaria standardizzata converge alla normale standard. Per n grande

possiamo scrivere l'approssimazione:

$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{e} \quad \sum_{i=1}^n X_i \approx \mathcal{N}(n\mu, n\sigma^2).$$

Velocità di convergenza. Dipende dalla forma della distribuzione originale. Per distribuzioni simmetriche bastano $n \geq 20$ –30; per distribuzioni fortemente asimmetriche potrebbero servire n più grandi. Per distribuzione con varianza infinita (es. Cauchy) il TCL non si applica.

Esempio intuitivo: si lancia un dado 100 volte. Ogni lancio ha $\mu = 3.5$ e $\sigma^2 = 35/12 \approx 2.917$. La somma dei 100 lanci è approssimativamente $\mathcal{N}(350, 291.7)$. La probabilità che la somma sia tra 330 e 370 è circa $\Phi\left(\frac{370-350}{\sqrt{291.7}}\right) - \Phi\left(\frac{330-350}{\sqrt{291.7}}\right) \approx \Phi(1.17) - \Phi(-1.17) \approx 75.8\%$.

Importanza del TCL:

1. Giustifica l'uso della distribuzione normale come modello approssimato in moltissimi contesti.
2. Permette di costruire intervalli di confidenza e test di ipotesi basati sulla normale.
3. Spiega perché molti fenomeni naturali (altezze, errori di misura, ecc.) appaiono gaussiani: sono somme di tanti fattori indipendenti.

9.4 Convergenza in distribuzione

Il TCL usa la nozione di convergenza in distribuzione.

Definizione. Una sequenza di v.a. X_n **converge in distribuzione** a X (scritto $X_n \xrightarrow{d} X$) se:

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \quad \text{per ogni } x \text{ punto di continuità di } F_X.$$

È la forma più debole di convergenza. Significa che la *forma* della distribuzione di X_n si avvicina a quella di X , non che le realizzazioni numeriche di X_n si avvicinino a quelle di X .

Confronto con le altre forme di convergenza:

- **Convergenza in probabilità** ($X_n \xrightarrow{p} X$): $\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$. Più forte della convergenza in distribuzione.
- **Convergenza quasi certa** ($X_n \xrightarrow{q.c.} X$): $P(\lim_n X_n = X) = 1$. La più forte.

Implicazioni: q.c. $\Rightarrow$ in probabilità $\Rightarrow$ in distribuzione. Le frecce inverse non valgono in generale.

10 Esercizi risolti

10.1 Esercizio 1 — Analisi combinatoria e probabilità classica

Problema. Da un mazzo standard di 52 carte si estraggono 5 carte senza rimpiazzo. Calcolare:

1. La probabilità di ottenere esattamente 2 assi.
2. La probabilità di ottenere almeno 1 asso.

Soluzione — Parte 1.

Il numero totale di mani di 5 carte è $\binom{52}{5} = 2\,598\,960$.

Per avere esattamente 2 assi: si scelgono 2 assi tra 4 ($\binom{4}{2} = 6$ modi) e le restanti 3 carte tra le 48 non-assi ($\binom{48}{3} = 17\,296$ modi).

$$P(2 \text{ assi}) = \frac{\binom{4}{2} \binom{48}{3}}{\binom{52}{5}} = \frac{6 \times 17\,296}{2\,598\,960} = \frac{103\,776}{2\,598\,960} \approx 0.0399.$$

Soluzione — Parte 2.

Usiamo il complementare: $P(\text{almeno 1 asso}) = 1 - P(\text{nessun asso})$.

Mani senza assi: $\binom{48}{5} = 1\,712\,304$.

$$P(\text{almeno 1 asso}) = 1 - \frac{1\,712\,304}{2\,598\,960} \approx 1 - 0.6588 = 0.3412.$$

Quindi circa il 34.1% delle mani contiene almeno un asso.

10.2 Esercizio 2 — Teorema di Bayes

Problema. Un test medico per una malattia rara ha le seguenti caratteristiche:

- Sensibilità (probabilità di positivo dato malato): $P(+ | M) = 0.99$.
- Specificità (probabilità di negativo dato sano): $P(- | \bar{M}) = 0.95$.
- Prevalenza della malattia: $P(M) = 0.001$ (1 su 1000).

Un paziente risulta positivo. Qual è la probabilità che sia effettivamente malato?

Soluzione.

Si vuole $P(M | +)$. Calcoliamo prima $P(+)$ con la legge della probabilità totale:

$$\begin{aligned} P(+) &= P(+ | M) P(M) + P(+ | \bar{M}) P(\bar{M}) \\ &= 0.99 \times 0.001 + 0.05 \times 0.999 \\ &= 0.00099 + 0.04995 = 0.05094. \end{aligned}$$

Quindi per Bayes:

$$P(M | +) = \frac{P(+ | M) P(M)}{P(+)} = \frac{0.00099}{0.05094} \approx 0.0194.$$

Interpretazione. Anche con un test molto accurato (99% sensibilità, 95% specificità), la probabilità di essere malati dato un esito positivo è solo circa **2%**. Questo risultato sorprendente — noto come *paradosso del falso positivo* — è dovuto alla bassissima prevalenza della malattia: i falsi positivi (sani che risultano positivi) sono molti di più dei veri positivi.

10.3 Esercizio 3 — Distribuzione binomiale e Poisson

Problema. Un centralino riceve in media 3 telefonate al minuto. Modellare il numero di telefonate in un minuto come Poisson con $\lambda = 3$. Calcolare:

1. $P(X = 0)$: nessuna telefonata.
2. $P(X \geq 2)$: almeno due telefonate.
3. Il numero medio e la varianza.

Soluzione.

$X \sim \text{Pois}(3)$.

Parte 1: $P(X = 0) = e^{-3} \frac{3^0}{0!} = e^{-3} \approx 0.0498$.

Parte 2: usiamo il complementare:

$$\begin{aligned} P(X \geq 2) &= 1 - P(X = 0) - P(X = 1) \\ &= 1 - e^{-3} - 3e^{-3} = 1 - 4e^{-3} \approx 1 - 0.1991 = 0.8009. \end{aligned}$$

Parte 3: $\mathbb{E}[X] = \lambda = 3$; $\text{Var}(X) = \lambda = 3$; $\sigma_X = \sqrt{3} \approx 1.73$.

In circa l'80% dei minuti, il centralino riceve almeno 2 telefonate.

10.4 Esercizio 4 — Distribuzione Normale e TCL

Problema. Il peso delle scatole prodotte da un impianto è $X \sim \mathcal{N}(500 \text{ g}, 100)$ (deviazione standard 10 g). Si carica un camion con $n = 64$ scatole.

1. Qual è la probabilità che una singola scatola pesi più di 515 g?
2. Qual è la probabilità che il peso totale del carico superi 32 200 g?

Soluzione — Parte 1.

$$P(X > 515) = P\left(Z > \frac{515 - 500}{10}\right) = P(Z > 1.5) = 1 - \Phi(1.5) \approx 0.0668.$$

Circa il 6.7% delle scatole pesa più di 515 g.

Soluzione — Parte 2.

Sia $S = X_1 + \dots + X_{64}$ il peso totale. Per il TCL (o per proprietà della normale):

$$S \sim \mathcal{N}(64 \times 500, 64 \times 100) = \mathcal{N}(32\,000, 6\,400), \quad \sigma_S = 80.$$

$$P(S > 32\,200) = P\left(Z > \frac{32\,200 - 32\,000}{80}\right) = P(Z > 2.5) = 1 - \Phi(2.5) \approx 0.0062.$$

Solo circa lo 0.62% dei carichi supera 32 200 g — un evento raro, che giustifica ad esempio il dimensionamento di margini di sicurezza.

10.5 Esercizio 5 — Disuguaglianza di Chebyshev vs Normale

Problema. X ha media $\mu = 200$ e deviazione standard $\sigma = 15$. Trovare un limite superiore per $P(|X - 200| \geq 45)$ usando Chebyshev. Se X fosse normale, quanto varrebbe esattamente?

Soluzione (Chebyshev). Con $\varepsilon = 45$:

$$P(|X - 200| \geq 45) \leq \frac{15^2}{45^2} = \frac{225}{2025} = \frac{1}{9} \approx 11.1\%.$$

Soluzione (Normale). Se $X \sim \mathcal{N}(200, 225)$, allora $\varepsilon = 45 = 3\sigma$:

$$P(|X - 200| \geq 45) = P(|Z| \geq 3) = 2(1 - \Phi(3)) \approx 2 \times 0.00135 = 0.27\%.$$

Confronto. Chebyshev dà 11.1%; la normale esatta dà 0.27%. Chebyshev è circa 40 volte più conservativo. Questo è il prezzo della generalità: Chebyshev vale per qualunque distribuzione,

ma può sovrastimare molto la probabilità di grandi deviazioni quando la distribuzione è in realtà ben concentrata.

11 Tavola riassuntiva delle distribuzioni

Distribuzione	Parametri	Media	Varianza	Applicazione tipica
Bernoulli	$p \in (0, 1)$	p	$p(1 - p)$	Esperimento binario
Binomiale	$n \in \mathbb{N}, p$	np	$np(1 - p)$	Numero successi in n prove
Poisson	$\lambda > 0$	λ	λ	Conteggio eventi rari
Uniforme disc.	$\{1, \dots, N\}$	$(N + 1)/2$	$(N^2 - 1)/12$	Esiti equiprobabili
Uniforme cont.	$a < b$	$(a + b)/2$	$(b - a)^2/12$	Arrivo casuale in intervallo
Normale	$\mu, \sigma^2 > 0$	μ	σ^2	Somme, errori, misure
Esponenziale	$\lambda > 0$	$1/\lambda$	$1/\lambda^2$	Tempo tra eventi Poisson

Risultato	Formula / Enunciato
Legge del complementare	$P(\bar{A}) = 1 - P(A)$
Regola dell'unione	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$
Probabilità condizionata	$P(A B) = P(A \cap B)/P(B)$
Regola del prodotto	$P(A \cap B) = P(A B) P(B)$
Legge prob. totale	$P(A) = \sum_i P(A B_i) P(B_i)$
Teorema di Bayes	$P(B_i A) = P(A B_i) P(B_i)/P(A)$
Indipendenza	$P(A \cap B) = P(A) P(B)$
Chebyshev	$P(X - \mu \geq \varepsilon) \leq \sigma^2/\varepsilon^2$
TCL	$(\bar{X}_n - \mu)/(\sigma/\sqrt{n}) \xrightarrow{d} \mathcal{N}(0, 1)$
Standardizzazione	$Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$