

Statistica Inferenziale — Guida Esaustiva allo Studio

Corso: Metodi Statistici per l'Informazione — Prof. Marco Lops *Università degli Studi di Napoli Federico II*

Contents

1	Generalità e fondamenti	3
1.1	Il problema dell'inferenza statistica	3
1.2	Statistica descrittiva vs. statistica inferenziale	3
1.3	Obiettivi fondamentali	3
1.4	Il modello statistico	3
1.5	Approccio Bayesiano vs. non-Bayesiano	4
2	Media campionaria e tipi di convergenza	4
2.1	La media campionaria	4
2.2	I tre tipi di convergenza	4
3	Distribuzione empirica e convergenza quasi certa	5
3.1	La distribuzione empirica come stimatore	5
3.2	Convergenza esponenziale e quasi certa	6
4	Il quadro generale dell'inferenza statistica	6
4.1	Dall'osservazione all'inferenza	6
4.2	La regola di Bayes come strumento unificante	6
5	Teoria delle decisioni — framework Bayesiano	7
5.1	Impostazione del problema	7
5.2	La matrice dei costi	7
5.3	Il rischio Bayesiano e la regola ottimale	7
6	Classificazione binaria ottimale	7
6.1	Il test del rapporto di verosimiglianza	7
6.2	Probabilità di errore condizionale e curva ROC	8
7	Verifica di ipotesi — Test di Neyman-Pearson	8
7.1	Il framework frequentista	8
8	Teoria della stima Bayesiana	9
8.1	Schema generale	9
8.2	Rischio Bayesiano per la stima	9
8.3	Proprietà degli stimatori Bayesiani	9
9	Stimatore MMSE — analisi approfondita	10
9.1	Derivazione	10
9.2	Proprietà dell'errore MMSE	10
10	Stimatore MAP — analisi approfondita	10
10.1	Derivazione	10
10.2	Relazione con MLE	11

11 Confronto MMSE vs. MAP e unicità Bayesiana	11
11.1 Quando MMSE e MAP coincidono	11
11.2 Tabella comparativa	11
12 Stima non Bayesiana e Massima Verosimiglianza	11
12.1 Il framework frequentista per la stima	11
12.2 Lo stimatore di Massima Verosimiglianza	12
13 Limite di Cramér-Rao — derivazione completa	12
13.1 Motivazione	12
13.2 Derivazione del CRB	12
14 Stima di parametri multipli	13
14.1 Estensione vettoriale	13
15 Stima MMSE Lineare (LMMSE)	13
15.1 Motivazione	13
15.2 Soluzione	13
15.3 L'algoritmo del gradiente per l'LMMSE	14
16 Minimi Quadrati, versione sequenziale e adattiva	14
16.1 Impostazione dei minimi quadrati	14
16.2 Versione sequenziale (aggiornamento ricorsivo)	14
16.3 Versione adattiva (LMS)	15
17 Tavole riassuntive e collegamenti concettuali	15
17.1 Mappa concettuale del corso	15
17.2 Tabella degli stimatori	15
17.3 Relazioni chiave da ricordare	16

1 Generalità e fondamenti

1.1 Il problema dell'inferenza statistica

Immaginiamo di osservare un campione di dati

$$\mathbf{x}^n = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n.$$

Il campione è il risultato di un esperimento casuale: se ripetessimo l'esperimento nelle stesse condizioni, otterremmo un campione diverso $\mathbf{x}'^n$. Questo fatto è cruciale: i dati non sono numeri fissi, ma realizzazioni di **variabili aleatorie**.

La **statistica inferenziale** si occupa di rispondere alla domanda:

Dati i campioni osservati, quali conclusioni possiamo trarre sulla distribuzione di probabilità che li ha generati?

In termini formali, si assume che esista una **legge di probabilità** — descritta da una distribuzione o da una famiglia di distribuzioni — e si cerca di inferirne le proprietà a partire dai dati.

1.2 Statistica descrittiva vs. statistica inferenziale

Questi due rami della statistica differiscono nella loro filosofia fondamentale:

- La **statistica descrittiva** si limita a caratterizzare il campione osservato. Calcola medie, varianze, istogrammi, percentili, ecc. Non fa alcuna assunzione su una popolazione più grande. I risultati sono validi *solo* per il campione osservato e non vengono generalizzati.
- La **statistica inferenziale** assume che il campione sia estratto casualmente da una *popolazione* — una distribuzione sottostante — e cerca di inferirne le proprietà. I risultati si applicano alla distribuzione, non solo al campione.

Esempio intuitivo: se misuriamo l'altezza di 100 studenti di una università e calcoliamo la media, la statistica descrittiva ci dice “la media in questo campione è 175 cm”. La statistica inferenziale dice “la media della *popolazione* degli studenti dell'università è probabilmente intorno a 175 cm, con un certo grado di incertezza”.

1.3 Obiettivi fondamentali

I due grandi obiettivi sono:

1. **Verifica di ipotesi (Hypothesis Testing):** dati i campioni, decidere quale tra un insieme di ipotesi sulla distribuzione è “vera”. Ad esempio: “i dati provengono da una distribuzione con media zero?” oppure “il sistema è in stato normale o anomalo?”.
2. **Stima di parametri (Parameter Estimation):** la distribuzione è nota *a meno di un parametro* θ (ad esempio, la media di una Gaussiana). Si vuole stimare θ dai dati.

1.4 Il modello statistico

Definizione. Un **modello statistico** è una famiglia di distribuzioni di probabilità parametrizzata da θ :

$$\mathcal{F} = \{f_{\mathbf{X}^n}(\mathbf{x}^n; \theta) : \theta \in \mathcal{S}\}.$$

Il parametro θ può essere scalare, vettoriale, discreto o continuo. La scelta del modello è il primo atto dell'analisi statistica ed è responsabilità del progettista: un modello sbagliato porta a conclusioni sbagliate indipendentemente dalla qualità dell'algoritmo di stima.

1.5 Approccio Bayesiano vs. non-Bayesiano

Esistono due filosofie principali, che differiscono su come trattano θ :

- **Approccio Bayesiano:** θ è trattato come la realizzazione di una variabile aleatoria Θ con una distribuzione *a priori* nota $f_{\Theta}(\theta)$. Questa distribuzione codifica la conoscenza disponibile su θ prima di osservare i dati. Dopo l'osservazione, si aggiorna alla distribuzione *a posteriori* tramite il teorema di Bayes.
- **Approccio frequentista (non-Bayesiano):** θ è trattato come una costante deterministica sconosciuta. Non si assume alcuna distribuzione *a priori* su θ . Si costruiscono stimatori basati solo sulla verosimiglianza dei dati.

Né l'uno né l'altro approccio è universalmente superiore: la scelta dipende dal contesto, dalla disponibilità di informazione *a priori* e dalla tradizione del campo. Questo corso le tratta entrambe.

2 Media campionaria e tipi di convergenza

2.1 La media campionaria

Dato un campione $(x_1, \dots, x_n)$, la **media campionaria** è definita come:

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i.$$

Dal punto di vista probabilistico, se $(X_1, \dots, X_n)$ sono v.a. i.i.d. con la stessa legge di X , la media campionaria è essa stessa una variabile aleatoria:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Le sue proprietà fondamentali sono:

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}[X], \quad \text{Var}[\bar{X}_n] = \frac{\text{Var}[X]}{n}.$$

La varianza decresce con n : più il campione è grande, più la media campionaria è concentrata attorno al suo valore atteso, che coincide con la media della popolazione. Questo è il punto di partenza per giustificare l'uso della media campionaria come stimatore della media vera.

2.2 I tre tipi di convergenza

La Legge dei Grandi Numeri afferma che $\bar{X}_n \rightarrow \mathbb{E}[X]$, ma ci sono diversi modi in cui questa convergenza può avvenire, con forze differenti. È importante distinguerli perché le garanzie che forniscono sono molto diverse.

Convergenza in media quadratica (MS).

Si dice che $\bar{X}_n \rightarrow \mathbb{E}[X]$ **in media quadratica** se:

$$\lim_{n \rightarrow \infty} \mathbb{E}[(\bar{X}_n - \mathbb{E}[X])^2] = 0.$$

Verifica: poiché $\mathbb{E}[\bar{X}_n] = \mathbb{E}[X]$ e $\text{Var}[\bar{X}_n] = \sigma^2/n$:

$$\mathbb{E}[(\bar{X}_n - \mathbb{E}[X])^2] = \text{Var}[\bar{X}_n] = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0.$$

La convergenza MS è la più facile da dimostrare perché si riduce a calcolare una varianza.

Convergenza in probabilità (debole).

Si dice che $\bar{X}_n \rightarrow \mathbb{E}[X]$ **in probabilità** se per ogni $\varepsilon > 0$: **(Debole)**

$$\lim_{n \rightarrow \infty} \Pr\{|\bar{X}_n - \mathbb{E}[X]| > \varepsilon\} = 0.$$

Significato: la “frequenza” con cui la media campionaria si allontana significativamente dalla media vera diventa arbitrariamente piccola. Si può ricavare dalla convergenza MS tramite la **disuguaglianza di Chebyshev**:

$$\Pr\{|\bar{X}_n - \mathbb{E}[X]| > \varepsilon\} \leq \frac{\text{Var}[\bar{X}_n]}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Questo è il contenuto della **Legge Debole dei Grandi Numeri (WLLN)**.

Convergenza quasi certa (forte).

Si dice che $\bar{X}_n \rightarrow \mathbb{E}[X]$ **quasi certamente (q.c.)** se:

$$\Pr\left\{\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}[X]\right\} = 1.$$

Significato: con probabilità 1, ogni singola realizzazione della sequenza $\bar{x}_1, \bar{x}_2, \bar{x}_3, \dots$ converge a $\mathbb{E}[X]$. Non si parla di frequenze, ma di ogni singolo “cammino” della sequenza. È un enunciato molto più forte. Questo è il contenuto della **Legge Forte dei Grandi Numeri (SLLN)**, la cui dimostrazione richiede strumenti più avanzati come il lemma di Borel-Cantelli.

Relazioni tra i tipi di convergenza:

$$\text{q.c.} \Rightarrow \text{in probabilità} \Rightarrow \text{in distribuzione}, \quad \text{MS} \Rightarrow \text{in probabilità}.$$

Le implicazioni inverse non valgono in generale, e q.c. e MS non si implicano a vicenda.

3 Distribuzione empirica e convergenza quasi certa

3.1 La distribuzione empirica come stimatore

Quando la distribuzione di X è sconosciuta, la prima cosa naturale da fare è “contare”: quante volte compare ciascun valore nel campione? Questo porta alla distribuzione empirica.

Definizione. Dato un campione i.i.d. da una distribuzione con PMF $\{p_X(a_i)\}_{i=1}^M$ su $\mathcal{X} = \{a_1, \dots, a_M\}$, la **distribuzione empirica** è:

$$f_n(a_i) = \frac{N_i}{n} = \frac{\#\{k : X_k = a_i\}}{n},$$

dove N_i è il numero di occorrenze di a_i nel campione.

La distribuzione empirica è essa stessa una variabile aleatoria: cambia da campione a campione. Il conteggio N_i segue una distribuzione Binomiale:

$$N_i \sim \mathcal{B}(n, p_X(a_i)),$$

da cui i momenti della frequenza relativa sono:

$$\mathbb{E}\left[\frac{N_i}{n}\right] = p_X(a_i), \quad \text{Var}\left[\frac{N_i}{n}\right] = \frac{p_X(a_i)(1 - p_X(a_i))}{n}.$$

Poiché la varianza tende a zero per $n \rightarrow \infty$, la frequenza empirica converge in MS (e quindi in probabilità) alla vera probabilità.

3.2 Convergenza esponenziale e quasi certa

La convergenza in probabilità garantisce che la frequenza empirica si avvicini alla vera probabilità, ma non dice quanto rapidamente. Un risultato più forte mostra che la convergenza è addirittura *esponenziale* in n .

Si può dimostrare, tramite il **bound entropico** sulle combinazioni binomiali e l'uso della **divergenza di Kullback-Leibler** (KL), che:

$$\Pr\{f_n(a_i) \neq p_X(a_i)\} \lesssim 2^{-nD_i},$$

dove $D_i = D_{\text{KL}}(q \| p_X(a_i)) > 0$ per $q \neq p_X(a_i)$.

Divergenza di Kullback-Leibler (caso binario).

$$D_{\text{KL}}(q \| p) = q \log \frac{q}{p} + (1 - q) \log \frac{1 - q}{1 - p} \geq 0,$$

con uguaglianza se e solo se $q = p$.

Poiché le probabilità decadono esponenzialmente, la loro somma è finita:

$$\sum_{n=1}^{\infty} \Pr\left\{\frac{N_i}{n} \neq p_X(a_i)\right\} < \infty.$$

Per il **lemma di Borel-Cantelli**, questo implica che $f_n(a_i) \rightarrow p_X(a_i)$ **quasi certamente**.

In pratica: questo giustifica l'utilizzo della distribuzione empirica come approssimazione della vera distribuzione. Per campioni sufficientemente grandi, la frequenza relativa di un evento è una buona approssimazione della sua probabilità.

4 Il quadro generale dell'inferenza statistica

4.1 Dall'osservazione all'inferenza

Supponiamo di osservare un campione $\mathbf{x}^n$ che sappiamo provenire da una famiglia di distribuzioni parametrica:

$$\mathbf{X}^n \sim f_{\mathbf{X}^n}(\mathbf{x}^n; \theta), \quad \theta \in \mathcal{S}.$$

Il parametro θ è ignoto. Le domande fondamentali dell'inferenza sono due: *stima* (qual è il valore di θ ?) e *test* (θ appartiene a questo sottoinsieme o a quest'altro?).

4.2 La regola di Bayes come strumento unificante

In ambito Bayesiano, il teorema di Bayes permette di aggiornare la distribuzione di θ dopo aver osservato i dati. Se θ ha prior $f_{\Theta}(\theta)$ e la verosimiglianza dei dati è $f_{\mathbf{X}^n|\Theta}(\mathbf{x}^n|\theta)$, la **distribuzione a posteriori** è:

$$f_{\Theta|\mathbf{X}^n}(\theta|\mathbf{x}^n) = \frac{f_{\mathbf{X}^n|\Theta}(\mathbf{x}^n|\theta) \cdot f_{\Theta}(\theta)}{f_{\mathbf{X}^n}(\mathbf{x}^n)},$$

dove il denominatore è la **verosimiglianza marginale**: $f_{\mathbf{X}^n}(\mathbf{x}^n) = \int f_{\mathbf{X}^n|\Theta}(\mathbf{x}^n|\theta') f_{\Theta}(\theta') d\theta'$.

Tutta l'informazione sui dati riguardo a θ è contenuta nella distribuzione a posteriori. La stima e il test sono diverse elaborazioni di questa distribuzione.

Se i campioni sono indipendenti è il prodotto delle densità della realizzazione del vettore aleatorio osservato

5 Teoria delle decisioni — framework Bayesiano

5.1 Impostazione del problema

La teoria delle decisioni fornisce il framework formale per prendere decisioni ottimali in presenza di incertezza. Si hanno M ipotesi mutualmente esclusive ed esaustive $\{H_1, \dots, H_M\}$, ciascuna corrispondente a una diversa distribuzione condizionale per il vettore di osservazioni $\mathbf{X}^n$:

$$\mathbf{X}^n | H_i \sim p_{\mathbf{X}^n}(\mathbf{x}^n | H_i), \quad i = 1, \dots, M.$$

Le probabilità a priori $P(H_i)$ delle ipotesi sono note.

5.2 La matrice dei costi

Definizione. La **matrice dei costi** $\mathbf{C} \in \mathbb{R}^{M \times M}$ ha elementi C_{ij} : il costo pagato quando si decide per H_i e lo stato di natura è H_j .

Convenzioni tipiche: $C_{ii} = 0$ (nessun costo per le decisioni corrette) e $C_{ij} \geq 0$ per $i \neq j$ (costo non negativo per gli errori).

5.3 Il rischio Bayesiano e la regola ottimale

Definizione. Il **rischio Bayesiano** è il costo medio atteso:

$$\mathcal{R} = \mathbb{E}[C(\hat{H}, H)] = \sum_{i,j} C_{ij} P(\text{decide } H_i | H_j) P(H_j).$$

Si può dimostrare che la regola che minimizza $\mathcal{R}$ è la **regola di decisione Bayesiana**: dato $\mathbf{x}^n$, scegliere l'ipotesi H_i che minimizza il rischio condizionale:

$$\hat{H}(\mathbf{x}^n) = \arg \min_i \sum_j C_{ij} f_{\mathbf{X}^n | H}(\mathbf{x}^n | H_j) P(H_j).$$

Caso speciale: costo 0-1. Se $C_{ij} = 1 - \delta_{ij}$ (ogni errore ha lo stesso costo 1), il rischio diventa la probabilità di errore e la regola ottimale è scegliere l'ipotesi a posteriori più probabile:

$$\hat{H}_{\text{MAP}}(\mathbf{x}^n) = \arg \max_i P(H_i | \mathbf{x}^n) = \arg \max_i f_{\mathbf{X}^n | H}(\mathbf{x}^n | H_i) P(H_i).$$

Questa è la **regola MAP (Maximum A Posteriori)**.

6 Classificazione binaria ottimale

6.1 Il test del rapporto di verosimiglianza

Il caso $M = 2$ (due ipotesi) è fondamentale e merita un trattamento dedicato. La regola MAP si semplifica in un confronto tra le verosimiglianze pesate dalle probabilità a priori.

Teorema (Neyman-Pearson, versione Bayesiana). La regola ottimale per il problema di classificazione binaria con costo 0-1 è il **test del rapporto di verosimiglianza (LRT)**:

$$L(\mathbf{x}^n) = \frac{p(\mathbf{x}^n | H_1)}{p(\mathbf{x}^n | H_2)} \underset{H_2}{\overset{H_1}{\gtrless}} \eta, \quad \eta = \frac{P(H_2)}{P(H_1)}.$$

La soglia η bilancia le probabilità a priori: se H_2 è a priori molto probabile, la soglia si alza e rendiamo più difficile decidere H_1 .

Caso ML: se $P(H_1) = P(H_2)$ (ipotesi equiprobabili), la soglia è $\eta = 1$ e la regola diventa:

$$L(\mathbf{x}^n) = \frac{p(\mathbf{x}^n|H_1)}{p(\mathbf{x}^n|H_2)} \underset{H_2}{\overset{H_1}{\geq}} 1,$$

cioè si sceglie l'ipotesi che **massimizza la verosimiglianza** dei dati: regola **ML (Maximum Likelihood)**.

6.2 Probabilità di errore condizionale e curva ROC

Le performance del test si caratterizzano tramite due probabilità:

$$P_D = P(\text{decide } H_1 | H_1) \quad (\text{probabilità di detezione}),$$

$$P_{FA} = P(\text{decide } H_1 | H_2) \quad (\text{probabilità di falso allarme}).$$

Al variare della soglia η , si ottiene la **curva ROC (Receiver Operating Characteristic)**: l'insieme dei punti $(P_{FA}(\eta), P_D(\eta))$ nel piano.

- La curva ROC di un test ottimale si trova sempre *sopra* la diagonale (che rappresenta la scelta casuale).
- Un test perfetto avrebbe $P_D = 1$ e $P_{FA} = 0$, cioè si troverebbe nell'angolo superiore sinistro.
- L'**area sotto la curva ROC (AUC)** misura sinteticamente la qualità del classificatore: AUC=1 è perfetto, AUC=0.5 è casuale.

Esempio — test sulla media Gaussiana. $X_1, \dots, X_n$ i.i.d., stessa varianza σ^2 , medie $\mu_1 > \mu_2$, $P(H_1) = P(H_2) = 1/2$. Il LRT si riduce a:

$$\bar{x}_n \underset{H_2}{\overset{H_1}{\geq}} \frac{\mu_1 + \mu_2}{2}.$$

La soglia ottimale è la mezza-somma delle due medie. Sotto H_1 , $\bar{X}_n \sim \mathcal{N}(\mu_1, \sigma^2/n)$, e la probabilità di detezione è:

$$P_D = Q\left(Q^{-1}(P_{FA}) - \frac{(\mu_1 - \mu_2)\sqrt{n}}{\sigma}\right),$$

dove Q è la coda della normale standard. Per $n \rightarrow \infty$, $P_D \rightarrow 1$ e $P_{FA} \rightarrow 0$: il test raggiunge la performance ideale asintoticamente.

7 Verifica di ipotesi — Test di Neyman-Pearson

7.1 Motivazione: i limiti del framework Bayesiano

Il framework Bayesiano richiede due ingredienti che in molte applicazioni pratiche non sono disponibili:

- le probabilità a priori $P(H_i)$ sulle ipotesi;
- una matrice dei costi $\mathbf{C}$ con valori numerici precisi.

In contesti come il radar, la diagnostica medica o i sistemi di sicurezza, queste quantità sono spesso impossibili da specificare in modo significativo. Il framework di Neyman-Pearson adotta allora un approccio diverso: invece di minimizzare un costo atteso, si fissa un vincolo su un tipo di errore e si minimizza l'altro.

7.2 Impostazione del problema e tipi di errore

Si definisce un'ipotesi nulla H_0 (lo “stato normale”) e un'ipotesi alternativa H_1 (l'“anomalia”). La regola di decisione $D(\mathbf{X}^n) \in \{0, 1\}$ partiziona lo spazio delle osservazioni in due regioni:

$$\Omega_1 = \{\mathbf{x}^n : D(\mathbf{x}^n) = 1\} \quad (\text{regione di rigetto di } H_0), \quad \Omega_0 = \Omega_1^c.$$

Esistono due tipi di errore, con nomi e conseguenze distinte:

Errore di tipo I (falso allarme): si decide H_1 quando H_0 è vera.

$$P_{FA} = \Pr\{D(\mathbf{X}^n) = 1 \mid H_0\} = \begin{cases} \int_{\Omega_1} f_{\mathbf{X}^n}(\mathbf{x}^n | H_0) d\mathbf{x}^n & \text{caso continuo} \\ \sum_{\mathbf{x}^n \in \Omega_1} p(\mathbf{x}^n | H_0) & \text{caso discreto} \end{cases}$$

Errore di tipo II (mancata rilevazione): si decide H_0 quando H_1 è vera.

$$\beta = \Pr\{D(\mathbf{X}^n) = 0 \mid H_1\} = P\{\text{decide } H_0 \mid H_1\}$$

Potenza del test (probabilità di rilevazione):

$$P_R = 1 - \beta = \Pr\{D(\mathbf{X}^n) = 1 \mid H_1\} = P\{\text{decide } H_1 \mid H_1\}$$

Il livello di significatività α è il valore massimo tollerato per P_{FA} .

Il trade-off fondamentale. Ridurre P_{FA} (alzare la soglia di decisione) aumenta β e riduce P_R : è impossibile minimizzare entrambi i tipi di errore simultaneamente. Neyman-Pearson risolve il trade-off con un vincolo:

$$\max_{\Omega_1} P_R \quad \text{soggetto a: } P_{FA} \leq \alpha.$$

7.3 Il lemma di Neyman-Pearson

Lemma di Neyman-Pearson. Il test che massimizza la potenza P_R per una probabilità di falso allarme fissata α è il **Likelihood Ratio Test (LRT)**:

$$L(\mathbf{x}^n) = \frac{f(\mathbf{x}^n | H_1)}{f(\mathbf{x}^n | H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \eta,$$

dove la soglia η è scelta in modo da soddisfare esattamente il vincolo:

$$\Pr\{L(\mathbf{X}^n) > \eta \mid H_0\} = \alpha.$$

Schema della dimostrazione. Sia $\Omega_1 = \{\mathbf{x}^n : L(\mathbf{x}^n) > \eta\}$ la regione dell'LRT e $\tilde{\Omega}_1$ una qualsiasi altra regione con $P_{FA}(\tilde{\Omega}_1) \leq \alpha$. Si può mostrare che:

- nei punti di $\Omega_1 \setminus \tilde{\Omega}_1$: $f(\mathbf{x}^n | H_1) > \eta \cdot f(\mathbf{x}^n | H_0)$
- nei punti di $\tilde{\Omega}_1 \setminus \Omega_1$: $f(\mathbf{x}^n | H_1) \leq \eta \cdot f(\mathbf{x}^n | H_0)$

Da ciò segue $P_R(\Omega_1) - P_R(\tilde{\Omega}_1) \geq \eta[P_{FA}(\Omega_1) - P_{FA}(\tilde{\Omega}_1)] \geq 0$. $\square$

Proprietà chiave del LRT.

- **Invarianza per trasformazioni monotone:** applicare una funzione monotona crescente $g(\cdot)$ a entrambi i membri non cambia la regione di decisione. In particolare si usa spesso il **log-likelihood ratio**:

$$\Lambda(\mathbf{x}^n) = \ln L(\mathbf{x}^n) = \ln f(\mathbf{x}^n | H_1) - \ln f(\mathbf{x}^n | H_0) \underset{H_0}{\overset{H_1}{\geq}} \ln \eta.$$

- **Sufficienza:** il LRT dipende dal campione solo attraverso $L(\mathbf{x}^n)$, che è una statistica sufficiente.

7.4 Esempio completo: test sulla media Gaussiana

Setting. $X_1, \dots, X_n$ i.i.d., con varianza σ^2 nota.

$$H_0 : X_i \sim \mathcal{N}(0, \sigma^2), \quad H_1 : X_i \sim \mathcal{N}(\mu, \sigma^2), \quad \mu > 0 \text{ ignoto.}$$

Passo 1 — Calcolo del LRT.

Poiché le osservazioni sono i.i.d., la verosimiglianza è il prodotto delle densità marginali. Il rapporto di verosimiglianza è:

$$L(\mathbf{x}^n) = \frac{\prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_k - \mu)^2}{2\sigma^2}\right)}{\prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{x_k^2}{2\sigma^2}\right)} = \exp\left(\frac{\sum_{k=1}^n x_k^2 - (x_k - \mu)^2}{2\sigma^2}\right).$$

Espandendo il numeratore dell'esponente:

$$x_k^2 - (x_k - \mu)^2 = 2\mu x_k - \mu^2,$$

e sommando su k :

$$L(\mathbf{x}^n) = \exp\left(\frac{n\mu\bar{x}_n - n\mu^2/2}{\sigma^2}\right) \underset{H_0}{\overset{H_1}{\geq}} \eta.$$

Passo 2 — Riduzione alla statistica sufficiente.

Prendendo il logaritmo e semplificando (con $\mu > 0$, la disuguaglianza non si inverte):

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i \underset{H_0}{\overset{H_1}{\geq}} \eta',$$

dove η' è una nuova soglia che assorbe le costanti. La **media campionaria** è la statistica sufficiente per questo test: riassume tutta l'informazione rilevante per la decisione.

Passo 3 — Calcolo della soglia η' dal vincolo su P_{FA} .

Sotto H_0 , la statistica di test ha distribuzione:

$$\bar{X}_n | H_0 \sim \mathcal{N}\left(0, \frac{\sigma^2}{n}\right).$$

Il vincolo $P_{FA} = \alpha$ diventa:

$$\Pr\left\{\bar{X}_n > \eta' \mid H_0\right\} = Q\left(\frac{\eta'}{\sigma/\sqrt{n}}\right) = \alpha \implies \eta' = \frac{\sigma}{\sqrt{n}} Q^{-1}(\alpha).$$

Passo 4 — Calcolo della potenza P_R .

Sotto H_1 , la statistica di test ha distribuzione:

$$\bar{X}_n | H_1 \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

La potenza del test è:

$$P_R = \Pr\left\{\bar{X}_n > \eta' \mid H_1\right\} = Q\left(\frac{\eta' - \mu}{\sigma/\sqrt{n}}\right) = Q\left(Q^{-1}(\alpha) - \frac{\mu\sqrt{n}}{\sigma}\right).$$

Calcolo delle probabilità di errore condizionale (caso MAP, ipotesi equiprobabili).

Con soglia $\eta = (\mu_1 + \mu_2)/2$ e due medie $\mu_1 > \mu_2$:

$$\Pr(e|H_1) = \Pr\left\{\bar{X}_n < \frac{\mu_1 + \mu_2}{2} \mid H_1\right\} = Q\left(\sqrt{n} \frac{\mu_1 - \mu_2}{2\sigma}\right)$$

$$\Pr(e|H_2) = \Pr\left\{\bar{X}_n > \frac{\mu_1 + \mu_2}{2} \mid H_2\right\} = Q\left(\sqrt{n} \frac{\mu_1 - \mu_2}{2\sigma}\right)$$

Le due probabilità di errore condizionale sono **uguali per simmetria**. La probabilità di errore totale è:

$$\Pr(e) = Q\left(\sqrt{n} \frac{\mu_1 - \mu_2}{2\sigma}\right) \xrightarrow{n \rightarrow \infty} 0.$$

Interpretazione. La probabilità di errore decresce monotonamente con $\sqrt{n}$ e con il rapporto $(\mu_1 - \mu_2)/\sigma$, che è la “separazione” tra le due ipotesi misurata in deviazioni standard. Per $n \rightarrow \infty$, il classificatore diventa perfetto indipendentemente da quanto siano vicine le due medie.

Comportamento asintotico del test NP.

La soglia η' dipende da σ e da α , ma **non da μ** . Questo significa che il test è ottimale per qualsiasi $\mu > 0$: è un caso di **test uniformemente più potente (UMP)**.

Per $n \rightarrow \infty$: $\eta' \rightarrow 0$ e $P_R \rightarrow 1$. Il test raggiunge la performance ideale ($P_{FA} = \alpha$, $P_R = 1$) asintoticamente.

7.5 La curva ROC

Definizione. La **curva ROC (Receiver Operating Characteristic)** è il luogo dei punti $(P_{FA}(\eta), P_R(\eta))$ al variare della soglia $\eta \in \mathbb{R}$:

$$\text{ROC} = \{(P_{FA}(\eta), P_R(\eta)) : \eta \in \mathbb{R}\}.$$

Per il test Gaussiano, eliminando η :

$$P_R = Q\left(Q^{-1}(P_{FA}) - \frac{\mu\sqrt{n}}{\sigma}\right).$$

- La curva ROC si trova sempre *sopra* la diagonale (che rappresenta la scelta casuale con $P_R = P_{FA}$).
- Al crescere di n o di $|\mu|/\sigma$, la curva si sposta verso l'angolo superiore sinistro ($P_{FA} = 0$, $P_R = 1$), che rappresenta il test ideale.
- L'**area sotto la curva ROC (AUC)** sintetizza la qualità del test: $\text{AUC} = 1$ è il test perfetto, $\text{AUC} = 0.5$ è la scelta casuale.

8 Teoria della stima Bayesiana

8.1 Schema generale

Il problema di stima Bayesiana si pone quando vogliamo stimare un parametro Θ trattato come variabile aleatoria. In ambito Bayesiano si assume:

- Il parametro Θ è una v.a. con prior noto $f_{\Theta}(\theta)$.
- Le osservazioni $\mathbf{X}^n | \Theta = \theta$ hanno distribuzione $f_{\mathbf{X}^n | \Theta}(\mathbf{x}^n | \theta)$.

La distribuzione a posteriori è:

$$f_{\Theta | \mathbf{X}^n}(\theta | \mathbf{x}^n) = \frac{f_{\mathbf{X}^n | \Theta}(\mathbf{x}^n | \theta) f_{\Theta}(\theta)}{\int f_{\mathbf{X}^n | \Theta}(\mathbf{x}^n | \theta') f_{\Theta}(\theta') d\theta'} = \ell_{\mathbf{x}^n}(\theta)$$

Tutta l'informazione disponibile su Θ dopo l'osservazione è contenuta in $f_{\Theta | \mathbf{X}^n}(\theta | \mathbf{x}^n)$.

8.2 Rischio Bayesiano per la stima

Definizione. Si definisce una **funzione di costo** $C(\hat{\theta} - \theta)$ che misura il costo dell'errore di stima. Il **rischio Bayesiano** è:

$$\mathcal{R} = \mathbb{E}[C(\hat{\Theta}(\mathbf{X}^n) - \Theta)] = \mathbb{E}_{\mathbf{X}^n}[\mathbb{E}[C(\hat{\Theta}(\mathbf{X}^n) - \Theta) | \mathbf{X}^n]].$$

Poiché l'aspettativa esterna non dipende da $\hat{\theta}$, minimizzare $\mathcal{R}$ equivale a minimizzare l'aspettativa interna per ogni $\mathbf{x}^n$:

$$\hat{\theta}(\mathbf{x}^n) = \arg \min_{\hat{\theta}} \int C(\hat{\theta} - \theta) f_{\Theta | \mathbf{X}^n}(\theta | \mathbf{x}^n) d\theta.$$

8.3 Proprietà degli stimatori Bayesiani

Per uno stimatore Bayesiano $\hat{\Theta}(\mathbf{X}^n)$ definiamo:

- **Non distorsione:** $\mathbb{E}[\hat{\Theta}(\mathbf{X}^n) - \Theta] = 0$, dove l'aspettativa è rispetto alla distribuzione congiunta di $(\mathbf{X}^n, \Theta)$.
- **Consistenza MS:** $\mathbb{E}[(\hat{\Theta}(\mathbf{X}^n) - \Theta)^2] \rightarrow 0$ per $n \rightarrow \infty$.
- **Consistenza debole:** $\Pr\{|\hat{\Theta}(\mathbf{X}^n) - \Theta| > \varepsilon\} \rightarrow 0$.
- **Consistenza forte:** $\hat{\Theta}(\mathbf{X}^n) \rightarrow \Theta$ q.c.

9 Stimatore MMSE — analisi approfondita

9.1 Derivazione

Con funzione di costo quadratica $C(e) = e^2$, il rischio è l'**errore quadratico medio (MSE)**:

$$\mathcal{R} = \mathbb{E}[(\hat{\Theta}(\mathbf{X}^n) - \Theta)^2].$$

Per ogni $\mathbf{x}^n$ fissato, si vuole minimizzare:

$$g(\hat{\theta}) = \int (\hat{\theta} - \theta)^2 f_{\Theta | \mathbf{X}^n}(\theta | \mathbf{x}^n) d\theta.$$

Derivando rispetto a $\hat{\theta}$ e annullando:

$$\frac{dg}{d\hat{\theta}} = 2 \int (\hat{\theta} - \theta) f_{\Theta | \mathbf{X}^n}(\theta | \mathbf{x}^n) d\theta = 0 \implies \hat{\theta} = \int \theta f_{\Theta | \mathbf{X}^n}(\theta | \mathbf{x}^n) d\theta.$$

Stimatore MMSE (Minimum Mean Square Error):

$$\hat{\Theta}_{\text{MMSE}}(\mathbf{x}^n) = \mathbb{E}[\Theta \mid \mathbf{X}^n = \mathbf{x}^n].$$

Lo stimatore MMSE è la **media a posteriori**.

Interpretazione: tra tutti i possibili stimatori, nessuno ha MSE inferiore allo stimatore MMSE. Questo risultato è indipendente dalla distribuzione a priori o dalla verosimiglianza: è una proprietà strutturale del costo quadratico.

9.2 Proprietà dell'errore MMSE

L'errore di stima $\tilde{\Theta} = \Theta - \hat{\Theta}_{\text{MMSE}}$ soddisfa la **proprietà di ortogonalizzazione**: è ortogonale (nel senso della covarianza) a qualsiasi funzione delle osservazioni. In particolare:

$$\mathbb{E}[\tilde{\Theta} g(\mathbf{X}^n)] = 0 \quad \text{per ogni funzione misurabile } g.$$

Il MSE minimo è:

$$\mathcal{R}_{\text{MMSE}} = \mathbb{E}[\text{Var}(\Theta \mid \mathbf{X}^n)] = \text{Var}(\Theta) - \text{Var}(\hat{\Theta}_{\text{MMSE}}).$$

10 Stimatore MAP — analisi approfondita**10.1 Derivazione**

Con funzione di costo 0-1 su $\mathbb{R}$ (cioè costo nullo solo se la stima è esattamente corretta, costo 1 altrimenti), nel limite in cui la “finestra” di costo zero diventa infinitamente stretta, il rischio Bayesiano diventa:

$$\mathcal{R} \approx 1 - f_{\Theta \mid \mathbf{X}^n}(\hat{\theta} \mid \mathbf{x}^n) \cdot \Delta\theta.$$

Minimizzare il rischio equivale a **massimizzare la densità a posteriori**:

Stimatore MAP (Maximum A Posteriori):

$$\hat{\Theta}_{\text{MAP}}(\mathbf{x}^n) = \arg \max_{\theta} f_{\Theta \mid \mathbf{X}^n}(\theta \mid \mathbf{x}^n) = \arg \max_{\theta} [f_{\mathbf{X}^n \mid \Theta}(\mathbf{x}^n \mid \theta) f_{\Theta}(\theta)].$$

Lo stimatore MAP è la **moda a posteriori**.

10.2 Relazione con MLE

Se il prior è uniforme su $\mathcal{S}$ (cioè non si ha informazione a priori), allora:

$$\hat{\Theta}_{\text{MAP}} = \arg \max_{\theta} f_{\mathbf{X}^n \mid \Theta}(\mathbf{x}^n \mid \theta) = \hat{\Theta}_{\text{MLE}}.$$

MAP e MLE coincidono sotto prior uniforme. Questo mostra che MLE è un caso particolare della stima Bayesiana, non un approccio radicalmente diverso.

11 Confronto MMSE vs. MAP e unicità Bayesiana**11.1 Quando MMSE e MAP coincidono**

Teorema (unicità). Se la funzione di costo $C(\cdot)$ è pari e convessa e la distribuzione a posteriori $f_{\Theta|\mathbf{X}^n}(\theta|\mathbf{x}^n)$ è **simmetrica rispetto alla sua media** $\mathbb{E}[\Theta|\mathbf{X}^n = \mathbf{x}^n]$, allora lo stimatore MMSE minimizza il rischio Bayesiano per qualsiasi $C(\cdot)$ in questa classe.

Corollario: se la distribuzione a posteriori è simmetrica unimodale (come la Gaussiana), media, mediana e moda coincidono, quindi $\hat{\Theta}_{\text{MMSE}} = \hat{\Theta}_{\text{MAP}}$.

Esempio intuitivo: nel caso Gaussiano-Gaussiano (prior Gaussiano, verosimiglianza Gaussiana), la distribuzione a posteriori è Gaussiana (simmetrica), quindi MMSE e MAP danno la stessa stima. Non è una coincidenza!

11.2 Tabella comparativa

Proprietà	MMSE	MAP
Funzione di costo	Quadratica	0-1 (puntuale)
Formula	$\mathbb{E}[\Theta \mathbf{X}^n]$	$\arg \max_{\theta} f_{\Theta \mathbf{X}^n}(\theta \mathbf{x}^n)$
Distorsione	In generale sì	Dipende dal prior
MSE Bayesiano	Minimo assoluto	Maggiore o uguale al MMSE
Complessità	Richiede integrale	Richiede massimizzazione
Coincidono quando	A posteriori simmetrica unimodale	

12 Stima non Bayesiana e Massima Verosimiglianza

12.1 Il framework frequentista per la stima

Quando non si dispone di un prior su θ , o quando non si vuole assumerne uno, si adotta l'approccio frequentista. Qui θ è una costante sconosciuta, non una variabile aleatoria. La qualità di uno stimatore $\hat{\Theta}(\mathbf{X}^n)$ si valuta tramite:

- **Distorsione (bias):** $b_n(\theta) = \mathbb{E}_{\theta}[\hat{\Theta}(\mathbf{X}^n)] - \theta$. Uno stimatore è **non distorto** se $b_n(\theta) = 0$ per ogni θ .
- **Varianza:** $\text{Var}_{\theta}[\hat{\Theta}(\mathbf{X}^n)]$.
- **MSE:** $\mathbb{E}_{\theta}[(\hat{\Theta}(\mathbf{X}^n) - \theta)^2] = \text{Var} + b_n^2(\theta)$.

È sempre possibile ridurre il bias aumentando la varianza (e viceversa): questo è il **trade-off bias-varianza**, fondamentale in tutto il machine learning.

12.2 Lo stimatore di Massima Verosimiglianza

Definizione. La **funzione di verosimiglianza** è:

$$L(\theta; \mathbf{x}^n) = f_{\mathbf{X}^n}(\mathbf{x}^n; \theta).$$

Lo stimatore **MLE (Maximum Likelihood Estimator)** è:

$$\hat{\Theta}_{\text{MLE}}(\mathbf{x}^n) = \arg \max_{\theta} L(\theta; \mathbf{x}^n) = \arg \max_{\theta} \ln L(\theta; \mathbf{x}^n).$$

Si lavora spesso con il **log-likelihood** $\ln L$ per ragioni computazionali: il logaritmo trasforma prodotti in somme (utile quando le osservazioni sono i.i.d.).

Proprietà asintotiche dell'MLE:

- **Consistenza:** $\hat{\theta}_{\text{MLE}} \rightarrow \theta$ in probabilità.
- **Asintoticamente non distorto:** $b_n(\theta) \rightarrow 0$.
- **Asintoticamente efficiente:** la varianza raggiunge il limite di Cramér-Rao per $n \rightarrow \infty$.
- **Asintoticamente normale:** $\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{d} \mathcal{N}(0, 1/I_1(\theta))$.

13 Limite di Cramér-Rao — derivazione completa

13.1 Motivazione

Il limite di Cramér-Rao (CRB) risponde a una domanda fondamentale: esiste un limite inferiore alla varianza di uno stimatore non distorto? La risposta è sì, ed è espressa in termini dell'**informazione di Fisher**.

Informazione di Fisher.

$$I_n(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \ln f_{\mathbf{X}^n}}{\partial \theta} \right)^2 \right] = -\mathbb{E}_\theta \left[\frac{\partial^2 \ln f_{\mathbf{X}^n}}{\partial \theta^2} \right].$$

Per n campioni i.i.d.: $I_n(\theta) = n I_1(\theta)$.

L'informazione di Fisher misura quanto “curva” è la log-verosimiglianza attorno al vero θ : una curvatura elevata significa che i dati sono molto informativi su θ .

13.2 Derivazione del CRB

Sia $\hat{\theta}(\mathbf{X}^n)$ un qualsiasi stimatore con bias $b_n(\theta)$.

Passo 1. Differenziando $\mathbb{E}_\theta[\hat{\theta}] = \theta + b_n(\theta)$ rispetto a θ e usando il trucco del score:

$$\mathbb{E}_\theta \left[(\hat{\theta}(\mathbf{X}^n) - \theta) \cdot \frac{\partial \ln f_{\mathbf{X}^n}}{\partial \theta} \right] = 1 + b'_n(\theta).$$

Passo 2. Riconoscendo il lato sinistro come una covarianza ($\mathbb{E}[\partial \ln f / \partial \theta] = 0$):

$$\text{Cov} \left[\hat{\theta}(\mathbf{X}^n), \frac{\partial \ln f_{\mathbf{X}^n}}{\partial \theta} \right] = 1 + b'_n(\theta).$$

Passo 3. Applicando la **disuguaglianza di Cauchy-Schwarz** $|\text{Cov}[A, B]|^2 \leq \text{Var}[A] \cdot \text{Var}[B]$:

$$[1 + b'_n(\theta)]^2 \leq \text{Var}[\hat{\theta}(\mathbf{X}^n)] \cdot I_n(\theta).$$

Passo 4. Isolando la varianza:

Limite di Cramér-Rao:

$$\text{Var}[\hat{\theta}(\mathbf{X}^n)] \geq \frac{[1 + b'_n(\theta)]^2}{I_n(\theta)}.$$

Per stimatori **non distorti** ($b_n = 0$, $b'_n = 0$):

$$\text{Var}[\hat{\Theta}(\mathbf{X}^n)] \geq \frac{1}{I_n(\theta)} = \frac{1}{n I_1(\theta)}.$$

Uno stimatore non distorto che raggiunge questo limite è detto **efficiente**. L'MLE è asintoticamente efficiente.

14 Stima di parametri multipli

14.1 Estensione vettoriale

Quando il parametro da stimare è un vettore $\theta \in \mathbb{R}^p$, tutte le nozioni precedenti si estendono naturalmente.

Matrice di informazione di Fisher:

$$\mathbf{I}_n(\theta) = \mathbb{E} \left[\frac{\partial \ln f_{\mathbf{X}^n}}{\partial \theta} \cdot \left(\frac{\partial \ln f_{\mathbf{X}^n}}{\partial \theta} \right)^T \right] \in \mathbb{R}^{p \times p}.$$

CRB vettoriale:

$$\text{Cov}[\hat{\Theta}(\mathbf{X}^n)] \geq \mathbf{I}_n^{-1}(\theta),$$

dove la disuguaglianza è intesa nel senso delle matrici semidefinite positive.

Equivalentemente, per ogni vettore $\mathbf{c}$:

$$\text{Var}[\mathbf{c}^T \hat{\Theta}] \geq \mathbf{c}^T \mathbf{I}_n^{-1} \mathbf{c}.$$

15 Stima MMSE Lineare (LMMSE)

15.1 Motivazione

Lo stimatore MMSE $\mathbb{E}[\Theta | \mathbf{X}^n]$ è ottimale, ma può essere difficile da calcolare (richiede la distribuzione a posteriori completa). Spesso si cerca il miglior stimatore *lineare* nelle osservazioni, che richiede solo la conoscenza di medie, varianze e covarianze.

Stimatore LMMSE. Si cerca il miglior stimatore della forma $\hat{\Theta} = \mathbf{a}^T \mathbf{X}^n + b$ che minimizza l'MSE:

$$(\mathbf{a}_{\text{LMMSE}}, b_{\text{LMMSE}}) = \arg \min_{\mathbf{a}, b} \mathbb{E}[(\Theta - \mathbf{a}^T \mathbf{X}^n - b)^2].$$

15.2 Soluzione

Dalla condizione di ortogonalizzazione (l'errore deve essere ortogonale alle osservazioni e alla costante), si ricava il sistema di **equazioni di Wiener-Hopf**:

$$\mathbf{M} \mathbf{a}_{\text{LMMSE}} = \mathbf{s},$$

dove $M_{ij} = \text{Cov}(X_i, X_j)$ è la matrice di covarianza delle osservazioni e $s_i = \text{Cov}(\Theta, X_i)$ è il vettore di correlazione incrociate. Quindi:

$$\mathbf{a}_{\text{LMMSE}} = \mathbf{M}^{-1} \mathbf{s}, \quad b_{\text{LMMSE}} = \mathbb{E}[\Theta] - \mathbf{a}_{\text{LMMSE}}^T \mathbb{E}[\mathbf{X}^n].$$

L'MSE minimo è:

$$J_{\min} = \sigma_{\Theta}^2(1 - \rho^2), \quad \rho^2 = \frac{\mathbf{s}^T \mathbf{M}^{-1} \mathbf{s}}{\sigma_{\Theta}^2}.$$

Quando $\rho = 0$ (nessuna correlazione tra Θ e $\mathbf{X}^n$), l'LMMSE degenera nella media del prior; quando $\rho = 1$, la stima è perfetta.

Relazione con il MMSE: se le distribuzioni sono Gaussiane, LMMSE e MMSE coincidono. In caso non Gaussiano, l'LMMSE è la migliore approssimazione lineare dell'MMSE.

15.3 L'algoritmo del gradiente per l'LMMSE

Per trovare $\mathbf{a}_{\text{LMMSE}} = \mathbf{M}^{-1} \mathbf{s}$ senza invertire esplicitamente la matrice $\mathbf{M}$ (operazione costosa per p grande), si usa l'**algoritmo del gradiente (steepest descent)**:

$$\mathbf{a}^{(k+1)} = \mathbf{a}^{(k)} - \gamma \nabla_{\mathbf{a}} J|_{\mathbf{a}^{(k)}} = \mathbf{a}^{(k)} - \gamma(\mathbf{M}\mathbf{a}^{(k)} - \mathbf{s}).$$

L'errore rispetto alla soluzione ottimale $\boldsymbol{\epsilon}^{(k)} = \mathbf{a}^{(k)} - \mathbf{a}_{\text{LMMSE}}$ evolve come:

$$\boldsymbol{\epsilon}^{(k+1)} = (\mathbf{I} - \gamma \mathbf{M}) \boldsymbol{\epsilon}^{(k)}.$$

Usando la decomposizione spettrale $\mathbf{M} = \mathbf{U} \boldsymbol{\Lambda} \mathbf{U}^T$, la condizione di convergenza è $|1 - \gamma \lambda_i| < 1$ per tutti gli autovalori, cioè:

$$0 < \gamma < \frac{2}{\lambda_{\max}(\mathbf{M})}.$$

La velocità di convergenza dipende dal **numero di condizionamento** $\kappa = \lambda_{\max}/\lambda_{\min}$: un κ grande rallenta la convergenza.

16 Minimi Quadrati, versione sequenziale e adattiva

16.1 Impostazione dei minimi quadrati

I minimi quadrati affrontano il problema di stima in un contesto non Bayesiano, dove si vuole minimizzare la somma dei residui al quadrato senza assumere alcuna distribuzione a priori.

Problema LS. Dato un modello lineare $\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\varepsilon}$, dove $\mathbf{y} \in \mathbb{R}^n$ è il vettore delle osservazioni, $\mathbf{X} \in \mathbb{R}^{n \times p}$ è la matrice di regressori (nota) e $\boldsymbol{\varepsilon}$ è il rumore, lo stimatore LS è:

$$\hat{\boldsymbol{\theta}}_{\text{LS}} = \arg \min_{\boldsymbol{\theta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2 = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Quando $\mathbf{X}^T \mathbf{X}$ è invertibile (cioè $\mathbf{X}$ ha rango p), la soluzione è unica. La matrice $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ è detta **pseudo-inversa di Moore-Penrose** di $\mathbf{X}$.

16.2 Versione sequenziale (aggiornamento ricorsivo)

Nell'elaborazione on-line dei segnali, le osservazioni arrivano una alla volta. Ricalcolare lo stimatore LS da zero ad ogni passo è computazionalmente costoso. Esiste un aggiornamento **ricorsivo** che mantiene la stessa soluzione:

Least Squares Sequenziale (RLS):

$$\begin{aligned}\mathbf{K}_{n+1} &= \mathbf{P}_n \mathbf{x}_{n+1} (\mathbf{x}_{n+1}^T \mathbf{P}_n \mathbf{x}_{n+1} + 1)^{-1} \quad (\text{guadagno di Kalman}) \\ \hat{\boldsymbol{\theta}}_{n+1} &= \hat{\boldsymbol{\theta}}_n + \mathbf{K}_{n+1} (y_{n+1} - \mathbf{x}_{n+1}^T \hat{\boldsymbol{\theta}}_n) \\ \mathbf{P}_{n+1} &= (\mathbf{I} - \mathbf{K}_{n+1} \mathbf{x}_{n+1}^T) \mathbf{P}_n.\end{aligned}$$

Il termine $y_{n+1} - \mathbf{x}_{n+1}^T \hat{\boldsymbol{\theta}}_n$ è detto **innovazione**: la parte della nuova osservazione non predicibile dal modello corrente. Il guadagno $\mathbf{K}_{n+1}$ bilancia fiducia nel modello precedente e nuova osservazione.

16.3 Versione adattiva (LMS)

L'algoritmo **LMS (Least Mean Squares)** è una versione stocastica e computazionalmente leggera dell'RLS. Aggiorna i coefficienti usando il gradiente calcolato su un solo campione:

$$\hat{\boldsymbol{\theta}}_{n+1} = \hat{\boldsymbol{\theta}}_n + \mu e_n \mathbf{x}_n, \quad e_n = y_n - \mathbf{x}_n^T \hat{\boldsymbol{\theta}}_n.$$

Il parametro $\mu > 0$ è il **passo di adattamento**. LMS non richiede l'inversione di matrici ed è il fondamento degli **equalizzatori adattativi** e dei filtri adattativi nei sistemi di comunicazione.

17 Tavole riassuntive e collegamenti concettuali

17.1 Mappa concettuale del corso

DATI $\mathbf{x}^n$		
	Verifica di ipotesi	Stima di parametri
Bayesiano (prior noto)	Regola MAP/LR $\arg \max_i P(H_i \mathbf{x}^n)$	MMSE: $\mathbb{E}[\Theta \mathbf{X}^n]$ MAP: $\arg \max f_{\Theta \mathbf{X}^n}$
Non Bayesiano (θ deterministico)	LRT con soglia α Neyman-Pearson	MLE: $\arg \max L(\theta; \mathbf{x}^n)$ LS: $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ Limite CRB

17.2 Tabella degli stimatori

Stimatore	Tipo	Costo	Formula	Quando usarlo
MMSE	Bayesiano	Quadratica	$\mathbb{E}[\Theta \mathbf{X}^n]$	Prior noto, MSE prioritario
MAP	Bayesiano	0-1	$\arg \max f_{\Theta \mathbf{X}^n}$	Prior noto, moda a posteriori
LMMSE	Bayesiano lin.	Quadratica	$\mathbf{M}^{-1} \mathbf{s}$	Solo 2° ordine disponibile
MLE	Freq.	–	$\arg \max \ln L$	No prior, garanzie asintotiche
LS	Freq. lin.	Residui	$(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$	Modello lineare, no prior
RLS	Adattivo	Residui	Aggiornamento ricorsivo	Dati in streaming
LMS	Adattivo	Residui	Gradiente stocastico	Complessità computaz. bassa

17.3 Relazioni chiave da ricordare

Relazione	Condizione / Nota
$\text{MMSE} = \text{MAP}$	A posteriori simmetrica unimodale (es. Gaussiana)
$\text{MAP} = \text{MLE}$	Prior uniforme
$\text{LMMSE} = \text{MMSE}$	Distribuzione congiunta Gaussiana
$\text{Var}[\hat{\Theta}] \geq 1/I_n(\theta)$	CRB per stimatori non distorti
MLE raggiunge CRB	Asintoticamente ($n \rightarrow \infty$)
$\text{Var}[\bar{X}_n] = \sigma^2/n$	Varianza della media campionaria
$I_n(\theta) = n I_1(\theta)$	Campioni i.i.d.